

RELATÓRIO

Atividade (A-2): Desenvolvimento inicial dos modelos RNA para análise educacional

Atividade (A-3): Implementação e Melhoria das Redes Neurais

Essas duas atividades são apresentadas no mesmo relatório.

Atividade (A-2) . Epígrafes 1-5

Atividade (A-3): Epígrafes 6-9

Ambas as atividades: Epígrafes 10 (Conclusão e discussão), 11 (bibliografia) e 12 (lista de esquemas, gráficos e tabelas).

0. Resumo executivo

Este resumo executivo apresenta o desenvolvimento de modelos de Redes Neurais Artificiais (RNA) aplicados à análise educacional, estabelecendo uma conexão entre a computação e a biologia.

A ideia fundamental do texto é a criação de uma “ponte neurodidática” que liga variáveis matemáticas das RNA a neurotransmissores reais e tipos de aprendizagem pedagógica. Através da simulação de um agente (um “rato virtual”), o estudo identifica que a aprendizagem ideal não resulta da maximização de uma única variável, mas da obtenção de um equilíbrio homeostático entre a visão de longo prazo (serotonina), a plasticidade associativa (acetilcolina) e o estado de alerta ou exploração (noradrenalina). Essa “proporção áurea” permite que o sistema seja eficiente sem entrar em colapso por estresse ou rigidez.

A arquitetura deste estudo baseia-se na premissa de que a aprendizagem não é um processo linear de acumulação de dados, mas um fenômeno emergente de equilíbrios dinâmicos. Ao empregar a figura do agente em um ambiente controlado — o “rato virtual” —, busca-se não apenas uma simulação computacional, mas a validação de um isomorfismo funcional entre o algoritmo de reforço e a neuroquímica cerebral. Essa “ponte neurodidática” permite traduzir parâmetros abstratos, como os coeficientes de aprendizagem, em variáveis biológicas tangíveis: a estabilidade estrutural proporcionada pela serotonina, a modulação da plasticidade mediada pela acetilcolina e a resposta adaptativa ao ambiente gerenciada pela noradrenalina. Em última análise, o modelo demonstra que a otimização educacional requer uma “homeostase pedagógica” em que o excesso de alerta não resulte em bloqueio noradrenérgico, nem a estabilidade excessiva em uma rigidez cognitiva que impeça a reconfiguração de esquemas mentais pré-existent.

Resumo por capítulos

Capítulo 1: Conceito, classificação e neurogênese As RNA são definidas como modelos matemáticos inspirados em redes biológicas que aprendem padrões em vez de seguir regras rígidas. Distingue-se entre as RNA tradicionais (contínuas) e as Redes Neurais

de Impulsos (SNN), que imitam a comunicação elétrica discreta do cérebro. Além disso, destaca-se a neurogênese como um processo vital para evitar o “esquecimento catastrófico” e permitir uma aprendizagem estável ao longo da vida.

Capítulo 2: Primeiros resultados da experimentação É utilizado um modelo ator-crítico em que um rato virtual procura um queijo num tabuleiro, medindo as iterações (α) necessárias para aprender. Observa-se um efeito de saturação ou “lei dos rendimentos decrescentes”, em que, após certas tentativas (β), a aprendizagem se estabiliza.

Capítulo 3: Modelagem e mineração de dados Através do cálculo de uma equação quadrática, identifica-se o “ponto ideal” da aprendizagem. O modelo restrito ($\gamma + \delta + \epsilon = 1$), que simula a economia metabólica cerebral, demonstra que a distribuição equilibrada de recursos é mais eficiente do que o potencial bruto. Utiliza-se Random Forest para expandir os resultados para milhares de previsões.

Capítulo 4: A ponte neurodidática I (Neurotransmissores) Estabelece-se a ligação entre variáveis e química cerebral: γ com a serotonina (orientação para o futuro), δ com a acetilcolina (ajuste de pesos sinápticos) e ϵ com a noradrenalina (exploração e alerta). Introduce-se o papel das células gliais na manutenção deste orçamento metabólico.

Capítulo 5: A ponte neurodidática II (Tipos de aprendizagem) Os neurotransmissores são associados a pedagogias: a serotonina à aprendizagem afetiva/adesiva, a acetilcolina à associativa e a noradrenalina à aversiva/defensiva. Conclui-se que a serotonina é a “âncora” que permite que o sistema funcione sem paralisia.

Capítulo 6: Repetimos a experiência para obter uma equação ainda mais precisa e, finalmente, a fórmula áurea dos tipos de aprendizagem, que também pode ser expressa com frações simples.

Capítulo 7: Consolidação e glutamato Usando uma rede de Hopfield, estuda-se a memória e o papel do glutamato na Potenciação de Longo Prazo (LTP). O experimento mostra que o sistema pode recuperar memórias completas a partir de estímulos parciais de 20%.

Capítulo 8: Categorização e sistema GABAérgico Por meio de Mapas Auto-organizados (SOM), simula-se como o GABA (neurotransmissor inibidor) “esculpe” o conhecimento. A inibição lateral silencia neurônios irrelevantes, permitindo uma categorização nítida e evitando a confusão cognitiva.

Capítulo 9: Análise com redes neurais espinhosas (SNN) Os resultados são validados com modelos SNN, mais sensíveis ao ruído temporal. O mínimo de aprendizagem ideal é confirmado.

Capítulo 10: Conclusões e discussão O sucesso educacional depende de um equilíbrio delicado entre plasticidade e inibição. Recomenda-se que os ambientes pedagógicos promovam segurança emocional, resolução de problemas e um nível de estresse controlado.

1. Conceito, classificação e objetivo educacional das Redes Neurais Artificiais e considerações sobre a neurogênese

1.1. Conceito de Rede Neural Artificial

Uma Rede Neural Artificial (RNA) é um modelo matemático inspirado no funcionamento das Redes Neurais Biológicas (RNB) ou Naturais. Uma RNA faz parte do campo da Inteligência Artificial e consiste em um sistema de “neurônios” interconectados (nós) que processam informações em camadas. Os pontos principais de uma RNA são:

- **Aprendizagem:** Ao contrário de um programa comum, ela aprende a identificar padrões por meio de dados, em vez de seguir regras rígidas.
- **Estrutura:** é composta por uma camada de entrada, camadas ocultas (onde ocorre o processamento real) e uma camada de saída.
- **Utilidade:** são fundamentais para tarefas complexas, como reconhecimento de voz, tradução de idiomas e diagnóstico médico.

Resumindo: o objetivo de uma rede neural é resolver problemas da mesma forma que nós faríamos, mas com a velocidade e o poder de processamento de um computador.

1.2. Classificação das redes neurais artificiais

Para os fins deste Relatório, são introduzidas duas classificações.

a) Distinção entre uma RNA (Rede Neural Artificial) tradicional, que é matemática e contínua, e uma Rede Neural de Impulsos (SNN, pela sigla em inglês: *Spiking Neural Network*), que é temporal e discreta.

Outros autores, como Schmidgall et al. (2024), têm utilizado a SNN, pois buscam imitar com maior precisão o funcionamento das neurônios reais em comparação com as redes neurais artificiais (RNA) convencionais.

Ao contrário das RNA padrão, que utilizam valores contínuos (taxas de disparo), as SNN incorporam a noção de tempo em sua comunicação. Os neurônios de uma SNN acumulam informações ao longo do tempo na forma de um potencial de membrana. Quando esse potencial ultrapassa um determinado valor limite, o neurônio emite um impulso binário ou “spike” para suas conexões pós-sinápticas e seu potencial é reiniciado. Embora binários e de curta duração, foi demonstrado teoricamente que os impulsos podem conter mais informações do que as representações baseadas em taxas das RNA.

Um dos modelos mais utilizados para descrever o comportamento dessas neurôneas é o *Leaky Integrate-and-Fire* (LIF). Esse modelo é definido matematicamente por meio de uma equação na qual o potencial de membrana depende da constante de tempo da membrana, do potencial de repouso e da corrente injetada. Essa estrutura permite que a rede processe informações que são altamente correlacionadas temporal e espacialmente, refletindo melhor a realidade física do que as RNA tradicionais, utilizadas aqui (sobre as eventuais vantagens, cf. Schmidgall et al. 2024).

As diferenças mais importantes entre uma RNA e uma SNN são apresentadas na tabela a seguir:

TABELA 1.1. DISTINÇÃO ENTRE RNA E SNN

Característica	Rede Neuronal Artificial (RNA)	Rede Neuronal de Impulsos (RNI)
Unidade de informação	Valores numéricos contínuos (por exemplo, 0,52, 0,89).	Impulsos ou “Spikes” (eventos discretos no tempo).
Dimensão temporal	Não possui uma noção real de tempo; os dados passam em “blocos”.	O tempo é fundamental. A rede processa quando o impulso ocorre.
Consumo de energia	Elevado (todos os nós são ativados e calculam em cada ciclo).	Muito baixo (ativação assíncrona: só consome energia quando há um “pico”).
Aprendizado	Baseado no gradiente (<i>retropropagação</i> padrão).	Baseado na plasticidade temporal (por exemplo, STDP: <i>Spike-Timing-Dependent Plasticity</i>).
Inspiração	Biológica de primeira/segunda geração (simplificada).	Terceira geração: imita fielmente a comunicação elétrica das neurônios reais.

Fonte: Elaboração própria.

Neste relatório, utilizaremos as RNA e, posteriormente, ratificaremos os resultados com SNN.

b) As Redes Neurais Artificiais (RNA) se destacam por sua grande versatilidade de implementação, pois podem ser executadas de diversas maneiras, de acordo com as necessidades do usuário. É possível desenvolvê-las e testá-las por meio de programas de desktop especializados em análise de dados, utilizar plataformas online (como Google Colab ou ferramentas sem código) que eliminam a necessidade de configurar hardware local, ou construí-las do zero por meio da programação em Python. Esta última opção é a mais comum atualmente, graças a bibliotecas poderosas como TensorFlow, Keras ou PyTorch, que permitem projetar arquiteturas personalizadas com controle total sobre o aprendizado e o processamento de informações.

Neste relatório, utilizaremos tanto programas de desktop (como o Simbrain 3.07) quanto RNA construídas por meio da programação em Python.

1.3. Aplicação das Redes Neurais Artificiais em estudos sobre educação

As redes neurais artificiais consolidaram-se como uma ferramenta ideal para estudar a aprendizagem humana devido à sua capacidade de *emular de forma simplificada a plasticidade cerebral*. Ao imitar a estrutura de nós interconectados e o ajuste de pesos sinápticos, essas redes permitem que os pesquisadores criem ambientes controlados onde podem observar fenômenos análogos à *cognição humana*, como a formação de conceitos, o reconhecimento de padrões e a correção de erros. Em vez de se limitarem a teorias abstratas, as RNA oferecem um modelo dinâmico que ajuda a compreender como a exposição repetida a dados transforma a arquitetura do conhecimento, proporcionando uma janela computacional única para os processos biológicos e psicológicos que regem a nossa própria forma de aprender.

1.4. Considerações sobre a neurogênese

Nas diferentes experiências que realizaremos com diferentes RNA (descritas nas seções a seguir), embora sejam utilizados diferentes modelos, todos têm logicamente um número determinado de neurônios artificiais. Este procedimento, portanto, necessariamente deixa de lado o processo de *neurogênese*.

A neurogênese é o processo biológico pelo qual novas neurônios são geradas e integradas aos circuitos neuronais já existentes. Embora esse processo seja especialmente intenso durante o desenvolvimento embrionário, Schmidgall et al. (2024) destacam que ele continua ocorrendo durante toda a vida adulta em regiões específicas do cérebro. Em mamíferos adultos, a neurogênese está localizada principalmente em três áreas-chave:

- A zona subventricular dos ventrículos laterais.
- A amígdala.
- O giro dentado da formação hipocampal.

Esta última localização é fundamental para o nosso texto, uma vez que o hipocampo é a região associada à ação da serotonina (nossa variável γ mais adiante) e da acetilcolina (variável δ) nos processos de memória e aprendizagem.

A taxa de criação de novos neurônios não é estática; ela é influenciada por fatores ambientais e comportamentais:

- Ambientes enriquecidos: Está comprovado que viver em ambientes estimulantes aumenta a neurogênese em comparação com condições padrão.
- Exercício físico: O exercício aeróbico e sustentado aumenta a proliferação de progenitores neuronais no hipocampo.
- Fatores negativos: o estresse e o envelhecimento tendem a reduzir a taxa de neurogênese.

Ainda de acordo com Schmidgall et al. (2024), uma das maiores limitações das Redes Neurais Artificiais (RNA) atuais é o esquecimento catastrófico, em que o aprendizado de novas informações apaga as anteriores. A neurogênese biológica é proposta como uma solução para esse problema pelas seguintes razões:

- Permite que o cérebro seja um meio incrível para a aprendizagem ao longo da vida, mantendo um tamanho relativamente fixo, mas renovando e expandindo suas capacidades de codificação.
- Ajuda os organismos a se adaptarem de maneira estável a ambientes em mudança, facilitando a assimilação de novos conhecimentos sem desestabilizar os circuitos antigos.

2. Primeiros resultados da experimentação com RNA

2.1. Introdução


Para as pessoas que não estão familiarizadas com um RNA, faremos uma breve introdução sobre o seu funcionamento.

Imaginemos um rato em um labirinto que precisa alcançar um pedaço de queijo. Esse é o experimento típico para observar como o pequeno roedor *aprende*. Atualmente, podemos substituir um rato real por um virtual e estudar seu aprendizado. Em vez de um labirinto, suponhamos que o rato virtual se encontra num tabuleiro de xadrez virtual, no qual ocupa uma determinada casa. O rato pode realizar um movimento e deslocar-se para uma casa vizinha. Este movimento simples é uma *iteração*. Podemos também supor que não se pode deslocar na diagonal entre as casas (como um bispo), mas sim em linha reta (como uma torre). Imaginemos também que nossa ratazana virtual começa na casa *a1* do tabuleiro (a que se encontra no vértice inferior esquerdo) e que na casa *h8* (a oposta na diagonal, a que se encontra no vértice superior direito) existe um queijo virtual. O rato se move livremente pelo tabuleiro. Por exemplo, de *a1* ele pode passar para *a2* ou *b1* (mas não para *b2*, na diagonal). Após um número finito de movimentos (*iterações*), ele alcançará a casa *h8*. Sabemos que o mínimo de iterações é 14, mas o máximo pode ser um número muito alto. Então, quando alcança o queijo virtual, ela volta a começar em *a1*. Bem, na segunda *tentativa* ou *repetição*, ela terá *aprendido algo* e, portanto, essa segunda tentativa, em princípio, deveria levar menos tempo para chegar ao queijo virtual, ou seja, menos *iterações*, a menos que ela tenha muita vontade de vagar pelo tabuleiro. Imaginemos agora que podemos controlar algumas variáveis do nosso rato virtual, como a permanência desse primeiro aprendizado em sua memória de rato virtual, seu desejo de alcançar o queijo ou sua vontade de vagar pelas caixas. Assim, poderíamos definir determinadas *variáveis independentes* (aqui se fala de memória, desejo, etc. Mais adiante definiremos de forma mais rigorosa as variáveis independentes, pelo que estes exemplos têm apenas uma função introdutória, mas não serão seguidos tal como estão). Assim, para um determinado número de *tentativas* e es ou *repetições* (que, por exemplo, alcance 10 vezes o queijo virtual e volte à casa de partida, ou 20, ou 30...), o número total de

iterações, ou seja, de deslocamentos entre as casas do tabuleiro de xadrez, poderia ser considerado a *variável dependente*. Se o leitor compreendeu o exemplo, pode agora imaginar uma RNA como uma rede de neurônios virtuais, dispostos como casas de xadrez, e o deslocamento do rato mecânico como o movimento de impulsos, que são modulados por algumas variáveis, que não são as indicadas, embora também possamos recontar *tentativas* e *iterações*. Essa simulação simples de aprendizagem é chamada de *modelo ator-crítico* (já que há um ator que decide o movimento – a ratazana, que se move pelo tabuleiro virtual – e um crítico que avalia se esse movimento a aproximou do queijo e gera o sinal de reforço que modifica os pesos sinápticos) ou também é conhecido como reforço (cf. Sutton & Barto 2015).

Utilizamos uma RNA, no nosso caso, em primeiro lugar, a fornecida pelo software Simbrain (utilizamos a versão 3.07), e definimos uma série de variáveis que designamos com as primeiras letras do alfabeto grego. A *variável dependente*, ou seja, o resultado final que vamos controlar e que é o número de *iterações*, será designada com a letra α . O número de *tentativas* será formulado com a letra β . As três variáveis que consideraremos *independentes* serão designadas com as letras $\gamma, \delta, \epsilon^1$. Desta forma, podemos simbolizar o que vamos fazer com a RNA da seguinte maneira:

ESQUEMA 2.1. DIAGRAMA DAS EXPERIÊNCIAS COM RNA



No texto anterior, falamos sobre *tempo* de aprendizagem e *iterações*. Não são a mesma coisa. As *iterações* referem-se aos passos ou ciclos que uma RNA ou um modelo de simulação realiza para processar informações e atualizar seus estados. Cada *iteração* representa um passo de *tempo discreto* no qual são calculadas as atividades das neurônios, propagam-se os sinais através das conexões sinápticas e modificam-se os *pesos* dessas

¹ Naturalmente, teria sido mais natural iniciar a atribuição das letras gregas com as variáveis independentes, mas procedemos desta forma porque nas RNA já existem duas letras atribuídas a variáveis independentes (γ e ϵ) e assim a ordem coincide.

conexões, se for o caso. No entanto, o tempo resultante (ou seja, a soma dos *tempos discretos*) também depende da velocidade de processamento do computador onde a RNA está instalada. Ou seja, uma RNA pode produzir as mesmas iterações, que simulam um determinado tempo de aprendizagem, embora o tempo real em que são processadas seja diferente dependendo do computador onde temos a RNA. Por isso, na pesquisa que descrevemos aqui, não é necessário medir os tempos do computador, mas sim suas iterações, porque o tempo depende da velocidade com que são processadas. Ou melhor, trata-se de medir quantas iterações são necessárias para completar uma determinada quantidade de tentativas. Mas quantas tentativas são necessárias? Por uma questão de clareza, tentaremos abordar essa questão antes mesmo de abordar a explicação das demais variáveis independentes.


2.2. A questão do número de tentativas (variável β)

Agora devemos abordar a questão do número de tentativas (que denominamos variável β). Quantas tentativas são necessárias?

Por se tratar de uma dinâmica de *aprendizagem*, ocorre um efeito de *saturação*. Esse fenômeno de saturação é o que ocorre, por exemplo, quando colocamos açúcar (ou qualquer adoçante substituto) no café (ou em qualquer substituto amargo). Se adicionarmos, por exemplo, uma colher de açúcar, notaremos que a bebida fica mais doce, e se colocarmos outra, notaremos que fica ainda mais doce, mas *não o dobro*, porque se continuarmos adicionando, chegará um momento em que seremos incapazes de detectar a doçura que cada nova colher adiciona. Talvez entre a nona e a décima colher, por exemplo, já não notaremos diferença. O sabor doce ficou *saturado*. Isso geralmente é representado pela chamada *curva logarítmica*, cujo crescimento gradualmente se detém até se tornar assintótica com a horizontal (veja o gráfico a seguir). É a chamada lei dos rendimentos decrescentes. No nosso caso, o da aprendizagem, é fácil entender que ocorre o mesmo. Nossa ratazana virtual consumirá mais iterações para alcançar seu queijo virtual entre a 5ª e a 10ª tentativa do que entre a 15ª e a 20ª tentativa, porque *ela terá aprendido* alguma coisa (se considerarmos constantes as variáveis independentes, seja qual for o seu valor), porque *precisamente* o que estamos medindo é *esse efeito* de aprendizagem.

Embora ainda não tenhamos explicado em que consistem as variáveis independentes γ , δ e ϵ , o leitor pode compreender facilmente o gráfico a seguir. A essas três variáveis, cujo valor na pesquisa pode oscilar entre 0,0 e 1,0, atribuímos o valor 0,5 (ou seja: $\gamma = \delta = \epsilon = 0,5$). Ao mantê-las constantes, a única variável independente que varia é o número de *tentativas* (β), representado no eixo X , e a variável dependente é o número de *iterações* (α), representado no eixo Y . Em termos formais: *dado que, neste caso, γ , δ e ϵ são constantes, $\alpha = f(\beta)$.*

GRÁFICO 2.1. SATURAÇÃO DAS TENTATIVAS COM RNA



Fonte: Elaboração própria com Simbrain.

Vejamos este gráfico 1 em detalhes. Fizemos 5 tentativas e o resultado foi 186 iterações; com 10, obtivemos 374; com 15, 468 iterações; com 20, 564, e assim por diante. A representação gráfica mostra bem o efeito de saturação. Se traçarmos a linha de tendência logarítmica (a curva do gráfico), observamos que ela se aproxima gradualmente da linha horizontal. Portanto, o valor de β (o número de repetições, ou seja, um número natural) não pode ser muito grande, porque então o efeito de saturação entra em ação, nem muito pequeno, porque então o acaso pode desempenhar um papel maior. Por isso, estabeleceremos um valor constante de $\beta = 20$ no nosso caso. Poder-se-ia pensar que, com isso, estamos a minar a nossa vontade de alcançar resultados universais e necessários, mas não é assim, porque o procedimento posterior conseguirá *modelar* os resultados, ou


seja, *suavizar* os eventuais resultados divergentes ou *destilar* a lógica subjacente dos dados resultantes usando inteligência artificial.

Como no caso das redes neurais biológicas, as RNA nem sempre produzem o mesmo resultado. Ou seja, para os mesmos valores de β , δ , ε e γ , não há garantias de que α apresente o mesmo resultado. Isso não acontece com um rato real nem com um rato virtual. O que interessa à ciência é desvendar a lógica subjacente, que será posteriormente *refinada* com diversos procedimentos matemáticos e informáticos.

2.3. Resultado dos experimentos

Recapitulemos: temos uma RNA preparada para simular um processo de aprendizagem; controlaremos cinco variáveis: uma que é mais uma constante (β , o número de tentativas), outras três que são variáveis independentes (δ , ε e γ) e outra, que consideraremos a variável dependente (α , o número de iterações). Observe o gráfico a seguir, que mostra a interface da RNA.

GRÁFICO 2.2. INTERFACE DO SIMBRAIN 3.07



Fonte: Elaboração própria.

Logicamente, ainda não explicamos por que nossas três variáveis independentes (δ , ϵ e γ) estão relacionadas com a *aprendizagem* (mais ainda, estão ligadas a *tipos* de aprendizagem). Relacionaremos uma coisa e outra com um nexso científico e, então, poderemos *cruzar a ponte* que permitirá reconstruir toda a argumentação deste escrito. Mas é preciso não nos adiantarmos e irmos passo a passo.

Procedemos à *experimentação* com a RNA e obtemos os resultados da tabela 1. A ordem das variáveis não é a do alfabeto grego, mas a da interface de programação da RNA. Na coluna da direita estão os resultados, ou seja, o número de *iterações*.

TABELA 2.1. RESULTADOS DAS EXPERIÊNCIAS COM RNA

γ	ϵ	δ	iterações (α)
0,0	0,0	0,0	1.130
0,2	0,0	0,0	1.208
0,4	0,0	0,0	1.431
0,6	0,0	0,0	1.625
0,8	0,0	0,0	1.420
1,0	0,0	0,0	1.598
0,0	0,2	0,0	1.685
0,2	0,2	0,0	1.402
0,4	0,2	0,0	1.957
0,6	0,2	0,0	1.308
0,8	0,2	0,0	1.702
1,0	0,2	0,0	1.835
0,0	0,4	0,0	1.624
0,2	0,4	0,0	1.489
0,4	0,4	0,0	1.449
0,6	0,4	0,0	1.675
0,8	0,4	0,0	1.395
1,0	0,4	0,0	2.842
0,0	0,6	0,0	1.604
0,2	0,6	0,0	1.854
0,4	0,6	0,0	1.590
0,6	0,6	0,0	1.658
0,8	0,6	0,0	1.923
1,0	0,6	0,0	1.413
0,0	0,8	0,0	1.721
0,2	0,8	0,0	1.859
0,4	0,8	0,0	1.248
0,6	0,8	0,0	1.383
0,8	0,8	0,0	1.527
1,0	0,8	0,0	2.444
0,0	1,0	0,0	2.311
0,2	1,0	0,0	2.031
0,4	1,0	0,0	2.379

0,6	1,0	0,0	2.093
0,8	1,0	0,0	2.149
1,0	1,0	0,0	2.354
0,0	0,0	0,2	893
0,2	0,0	0,2	373
0,4	0,0	0,2	475
0,6	0,0	0,2	333
0,8	0,0	0,2	504
1,0	0,0	0,2	333
0,0	0,2	0,2	833
0,2	0,2	0,2	378
0,4	0,2	0,2	363
0,6	0,2	0,2	454
0,8	0,2	0,2	529
1,0	0,2	0,2	427
0,0	0,4	0,2	1.031
0,2	0,4	0,2	468
0,4	0,4	0,2	526
0,6	0,4	0,2	429
0,8	0,4	0,2	455
1,0	0,4	0,2	556
0,0	0,6	0,2	1.333
0,2	0,6	0,2	616
0,4	0,6	0,2	563
0,6	0,6	0,2	621
0,8	0,6	0,2	663
1,0	0,6	0,2	569
0,0	0,8	0,2	1.526
0,2	0,8	0,2	1046
0,4	0,8	0,2	892
0,6	0,8	0,2	1.071
0,8	0,8	0,2	1.035
1,0	0,8	0,2	926
0,0	1,0	0,2	2.345
0,2	1,0	0,2	1.906
0,4	1,0	0,2	1.909
0,6	1,0	0,2	1.900
0,8	1,0	0,2	2.307
1,0	1,0	0,2	2.925
0,0	0,0	0,4	791
0,2	0,0	0,4	544
0,4	0,0	0,4	567
0,6	0,0	0,4	454
0,8	0,0	0,4	424
1,0	0,0	0,4	441
0,0	0,2	0,4	808
0,2	0,2	0,4	325
0,4	0,2	0,4	408
0,6	0,2	0,4	348
0,8	0,2	0,4	464
1,0	0,2	0,4	471
0,0	0,4	0,4	1.304
0,2	0,4	0,4	507
0,4	0,4	0,4	525
0,6	0,4	0,4	443
0,8	0,4	0,4	446
1,0	0,4	0,4	536
0,0	0,6	0,4	1.057
0,2	0,6	0,4	620

0,4	0,6	0,4	684
0,6	0,6	0,4	765
0,8	0,6	0,4	594
1,0	0,6	0,4	637
0,0	0,8	0,4	1.519
0,2	0,8	0,4	930
0,4	0,8	0,4	972
0,6	0,8	0,4	876
0,8	0,8	0,4	1.054
1,0	0,8	0,4	974
0,0	1,0	0,4	1.947
0,2	1,0	0,4	2.328
0,4	1,0	0,4	2.490
0,6	1,0	0,4	2.421
0,8	1,0	0,4	2.866
1,0	1,0	0,4	1.764
0,0	0,0	0,6	949
0,2	0,0	0,6	435
0,4	0,0	0,6	402
0,6	0,0	0,6	582
0,8	0,0	0,6	450
1,0	0,0	0,6	515
0,0	0,2	0,6	945
0,2	0,2	0,6	356
0,4	0,2	0,6	428
0,6	0,2	0,6	433
0,8	0,2	0,6	386
1,0	0,2	0,6	368
0,0	0,4	0,6	1.162
0,2	0,4	0,6	484
0,4	0,4	0,6	576
0,6	0,4	0,6	468
0,8	0,4	0,6	589
1,0	0,4	0,6	520
0,0	0,6	0,6	1.456
0,2	0,6	0,6	653
0,4	0,6	0,6	560
0,6	0,6	0,6	619
0,8	0,6	0,6	412
1,0	0,6	0,6	538
0,0	0,8	0,6	1.651
0,2	0,8	0,6	945
0,4	0,8	0,6	719
0,6	0,8	0,6	968
0,8	0,8	0,6	1.510
1,0	0,8	0,6	1.261
0,0	1,0	0,6	2.332
0,2	1,0	0,6	1.875
0,4	1,0	0,6	1.935
0,6	1,0	0,6	2.035
0,8	1,0	0,6	2.720
1,0	1,0	0,6	1.674
0,0	0,0	0,8	976
0,2	0,0	0,8	374
0,4	0,0	0,8	375
0,6	0,0	0,8	375
0,8	0,0	0,8	441
1,0	0,0	0,8	398
0,0	0,2	0,8	1.021

0,2	0,2	0,8	494
0,4	0,2	0,8	487
0,6	0,2	0,8	628
0,8	0,2	0,8	578
1,0	0,2	0,8	453
0,0	0,4	0,8	732
0,2	0,4	0,8	503
0,4	0,4	0,8	500
0,6	0,4	0,8	473
0,8	0,4	0,8	627
1,0	0,4	0,8	455
0,0	0,6	0,8	1.149
0,2	0,6	0,8	594
0,4	0,6	0,8	708
0,6	0,6	0,8	926
0,8	0,6	0,8	539
1,0	0,6	0,8	640
0,0	0,8	0,8	1.245
0,2	0,8	0,8	845
0,4	0,8	0,8	1.139
0,6	0,8	0,8	871
0,8	0,8	0,8	820
1,0	0,8	0,8	961
0,0	1,0	0,8	2.236
0,2	1,0	0,8	1.815
0,4	1,0	0,8	2.367
0,6	1,0	0,8	3.169
0,8	1,0	0,8	2.312
1,0	1,0	0,8	1.602
0,0	0,0	1,0	718
0,2	0,0	1,0	642
0,4	0,0	1,0	361
0,6	0,0	1,0	285
0,8	0,0	1,0	353
1,0	0,0	1,0	448
0,0	0,2	1,0	937
0,2	0,2	1,0	444
0,4	0,2	1,0	445
0,6	0,2	1,0	364
0,8	0,2	1,0	523
1,0	0,2	1,0	506
0,0	0,4	1,0	983
0,2	0,4	1,0	521
0,4	0,4	1,0	630
0,6	0,4	1,0	596
0,8	0,4	1,0	463
1,0	0,4	1,0	853
0,0	0,6	1,0	1.132
0,2	0,6	1,0	608
0,4	0,6	1,0	915
0,6	0,6	1,0	519
0,8	0,6	1,0	623
1,0	0,6	1,0	529
0,0	0,8	1,0	1.429
0,2	0,8	1,0	1.238
0,4	0,8	1,0	1.313
0,6	0,8	1,0	1.246
0,8	0,8	1,0	1.139
1,0	0,8	1,0	1.281

0,0	1,0	1,0	1.842
0,2	1,0	1,0	2.020
0,4	1,0	1,0	2.083
0,6	1,0	1,0	2.219
0,8	1,0	1,0	1.951
1,0	1,0	1,0	2.385

Fonte: Elaboração própria com Simbrain

A cada variável independente, que pode oscilar entre 0,0 e 1,0, atribuímos 6 valores possíveis (0,0, 0,2, 0,4, 0,6, 0,8 e 1,0), de modo que, tendo três variáveis independentes, o número de combinações possíveis é $6^3 = 216$. Na realidade, poderíamos dizer que realizamos 216 experimentos, com a vantagem de não termos precisado de 216 ratos reais absolutamente iguais, e que os ratos virtuais alcançaram 4.320 vezes o queijo virtual, para o que precisaram de 232.416 iterações (deslocamentos, ou seja, as vezes que o impulso passou de um neurônio artificial para outro).

É óbvio que poderíamos ter realizado mais experimentos, atribuindo mais valores às variáveis (por exemplo: 0,1, 0,2, 0,3... ou ainda mais: 0,10, 0,15, 0,20... ou mesmo: 0,100, 0,105, 0,110...), mas isso não é necessário, pois dispomos de dois procedimentos para investigar a lógica subjacente aos resultados da tabela 1.

A seguir, explicaremos os procedimentos de modelagem com os dados de nossa experimentação (tabela anterior).

3. Modelização: Cálculo da equação subjacente aos resultados da experimentação, definição de clusters e mineração de dados

3.1. Cálculo da equação subjacente aos resultados da experimentação

Trata-se agora de transferir os resultados da experiência (ou melhor, das experiências) para uma fórmula, ou seja, para uma equação, na qual a variável dependente (α , o número de iterações) é expressa em função das variáveis dependentes (δ , ε e γ). Para isso, é necessário um procedimento matemático certamente complicado: estabelecer um sistema de equações no qual temos três incógnitas (δ , ε e γ) e uma série de resultados. Explicaremos detalhadamente para pessoas que não estão familiarizadas com matemática.

É fácil entender que, se temos uma variável (digamos y) que varia em relação a outra (digamos x), podemos expressar a relação por meio de uma equação, na qual x pode apresentar expoentes; por isso, falaremos de equações de primeiro grau, de segundo grau, etc. Em uma equação de primeiro grau (do tipo: $y = ax + b$), a relação entre as duas variáveis é linear (os valores de x e y , representados em eixos cartesianos, formam uma linha *reta*). Ou melhor, podemos expressá-la ao contrário: se tivermos uma tabela com os valores de x e y , podemos representá-los em eixos cartesianos XY e podemos calcular a linha de tendência reta, que será a linha reta que mais se aproxima dos pontos da tabela (ou seja, cujas distâncias medidas por linhas perpendiculares à reta fornecem a menor soma). Como essa linha reta nos eixos cartesianos é definida por uma equação (do tipo: $y = ax + b$), podemos substituir a tabela com os valores por sua equação, que constitui seu modelo.

Ganhamos ainda mais precisão se, em vez de uma reta, descrevermos uma curva². Então, teríamos uma equação de segundo grau (do tipo: $y = ax^2 + bx + c$) ou superior, em que o *grau* se refere ao maior expoente que afeta a variável independente (x). Se, em vez de termos duas variáveis (x e y), tivermos mais, então a representação cartesiana é mais

² Na realidade, o gráfico sempre descreve linhas curvas, pois uma linha reta seria um arco de circunferência de raio infinito.

complexa porque precisa de mais dimensões, o que é mais difícil de representar e imaginar.

O problema para nossa pesquisa é *determinar* a equação (que, no nosso caso, tem três variáveis independentes e uma dependente), ou seja, a equação da linha de tendência que mais se aproxima dos resultados (e determinar até mesmo o quanto ela se aproxima, ou seja, a força do modelo). Felizmente, a Inteligência Artificial Generativa (IAG) evita cálculos demorados e permite descobrir rapidamente qual equação expressa *melhor* a variação da tabela 1.

Utilizamos dois modelos de inteligência artificial, que oferecem resultados muito semelhantes:

Gemini 3	$\alpha = 1241,2223 + 459,7197\gamma + 45,4190\varepsilon - 3012,3302\delta + 130,3060\gamma^2 + 424,4716\gamma\varepsilon - 461,3033\gamma\delta + 293,7314\varepsilon^2 - 122,9515\varepsilon\delta + 2929.9806\delta^2$
Kimi K2.5	$\alpha = 1568,90 - 2447,19\delta - 1584,07\varepsilon - 958,46\gamma + 1786,94\delta^2 + 2494,38\varepsilon^2 + 859,45\gamma^2 + 586,48\delta\varepsilon - 363,65\delta\gamma + 245,22\varepsilon\gamma$

No caso da primeira fórmula, as estatísticas que mostram a robustez da equação são as seguintes.

Estatística	Valor	Descrição
R ² (Coeficiente de d determinação)	0,8914	O modelo explica 89,14% da variabilidade dos dados.
R ² Ajustado	0,8856	Ajustado pelo número de variáveis; indica uma alta robustez.
RMSE (Erro quadrático médio)	172,45	O erro típico das previsões nas mesmas unidades que a variável α .
MAE (Erro absoluto médio)	131,12	O desvio médio absoluto entre o modelo e os dados reais.
F-statistic	154,32	Valor alto que confirma a significância global do modelo.

Valor p	< 0,0001	O modelo é altamente significativo (muito abaixo do limiar de 0,05).
---------	----------	--

No caso da segunda fórmula, as estatísticas que mostram a solidez da equação são as seguintes.

Estatística	Valor	Descrição
R ² (Coeficiente de determinação)	0,7716	O modelo explica 77,16% da variabilidade dos dados.
R ² Ajustado	0,76,16	Ajustado pelo número de variáveis; indica uma boa robustez.
RMSE (Erro quadrático médio)	330,34	O erro típico das previsões nas mesmas unidades que a variável α .
MAE (Erro absoluto médio)	243,36	O desvio médio absoluto entre o modelo e os dados reais.
F-statistic	77,34	Valor alto que confirma a significância global do modelo.
Valor p	< 0,0001	O modelo é altamente significativo (muito abaixo do limiar de 0,05).

3.2. Modelo restrito, de maior valor neurológico

Além disso, podemos introduzir uma restrição, a saber, que $\gamma + \varepsilon + \delta = 1$. Mais adiante, explicaremos o significado dessa restrição para o aprendizado.

O *mínimo restrito* é obtido com os seguintes valores:

	δ	ε	γ
Gemini 3	0,577	0,138	0,285
Kimi K2.5	0,5424	0,1262	0,3314

Observe-se que as duas IA oferecem resultados muito semelhantes.

O que pode ser simplificado mais ou menos assim:

$$\delta = \frac{1}{2}; \varepsilon = \frac{1}{8}; \gamma = \frac{3}{8};$$

Mas esta é uma caracterização provisória que será aperfeiçoada posteriormente.

Ou seja, ao forçar as variáveis independentes a somarem 1, o sistema se torna ainda mais eficiente (diminui de 1022 para 987 iterações). A melhor configuração possível é aquela em que as variáveis representam um conjunto limitado, o que tem um significado neurológico preciso que será comentado mais adiante.

O *máximo restrito* corresponde ao valor $\alpha \approx 2,168,04$ iterações, obtido de acordo com a equação com os valores:

$$\gamma = 0,0; \varepsilon = 1,0; \delta = 0,0$$

O que significa que, se fosse possível escolher apenas uma variável para obter o aprendizado, optar por ε seria a pior decisão possível, pois aumentaria o número de iterações, uma vez que possui o coeficiente quadrático mais pesado (1642,84).

3.3. Análise de clusters

Com os dados da tabela, também podemos realizar uma *análise de clusters*. A análise de clusters (ou agrupamento) é uma técnica estatística e de aprendizado automático que consiste em organizar um conjunto de dados em grupos, de modo que os elementos dentro de um mesmo grupo sejam muito semelhantes entre si e diferentes dos elementos de outros grupos. Por ser um método de aprendizado não supervisionado, o sistema não utiliza rótulos prévios, mas descobre padrões ocultos e estruturas naturais nos dados por conta própria. É uma ferramenta fundamental para segmentar perfis de comportamento,


organizar informações complexas e simplificar grandes volumes de dados em categorias compreensíveis. O resultado é apresentado na tabela 3.1:

TABELA 3.1. ANÁLISE DE CLUSTERS

Variável	Cluster 0 (Ótimo)	Cluster 1 (Crítico)	Cluster 2 (Estável/Baixo)	Cluster 3 (Intermediário)
γ	0,2 a 1,0	0,0 a 0,2	0,4 a 1,0	0,0 a 0,6
ϵ	0,0 a 0,4	0,6 a 1,0	0,6 a 1,0	0,2 a 0,6
δ	0,6 a 1,0	0,0 a 0,4	0,0 a 0,6	0,0 a 1,0
α	317 - 590	1800 - 2842	600 - 1100	1101 - 1799

O que pode ser representado no gráfico 3.1.

GRÁFICO 3.1. ANÁLISE DE CLUSTERS



Fonte: Elaboração própria com Gemini.

3.4. Expansão dos resultados com um programa de mineração de dados

Além do cálculo da equação anterior e do estabelecimento de máximos e mínimos (no modelo geral e no restrito), ainda podemos recorrer à Inteligência Artificial para fazer outra coisa com a tabela 2.1. Mas, neste caso, não utilizaremos a IAG, mas sim a chamada Inteligência Artificial Preditiva (IAP), mais concretamente um programa de mineração de dados conhecido como *Random Forest*.

A IAP, como o próprio nome indica, pode fazer previsões. Na tabela 1 temos o resultado de 216 experimentos (cada um com 20 tentativas), nos quais atribuímos diversos valores a três variáveis independentes e anotamos o resultado da variável dependente. Com a IAP podemos *multiplicar* o número de experimentos. Explicaremos brevemente como isso pode ser feito.

Partimos do conceito conhecido de *árvore de decisão* ou, melhor, de *previsão* (em inglês: *tree predictor*). Com essa noção, descrevemos práticas que nos são bem conhecidas, como, por exemplo, o que acontece na porta do pronto-socorro de um hospital: a fase de *triagem*. A equipe de saúde verifica uma série de indicadores (temperatura, pressão arterial, saturação de oxigênio no sangue, etc.) e, juntamente com o relato do paciente, *prevê* o que pode acontecer com ele. Em geral, nesse tipo de procedimento, o que se faz é dividir o conjunto de dados em subconjuntos menores e, por assim dizer, obter alguma conclusão sobre as características dos subconjuntos e sua relação mútua, de modo que se possam tomar decisões baseadas em sequências *se A, então B*, ou melhor, o que é conhecido na linguagem de programação como sentenças *if-then-else* (algo como: *se A, então B, e se não A, então C*).

Para chegar a uma *previsão* melhor, poderíamos supor não uma única *árvore* (um *tree predictor*), mas um conjunto delas, uma *floresta* (*forest*). Imaginemos um hospital em que, na porta do pronto-socorro, os pacientes passariam por 25 serviços de triagem. Sem dúvida, obteríamos uma previsão mais precisa. Ou seja, teríamos então conjuntos de árvores de previsão (*tree ensembles*). É isso que fazem programas de IAP como Gradient Boosting ou AdaBoost.


Mas poderíamos até supor um sistema aleatório que considerasse 20 serviços aleatórios desses 25 para eliminar qualquer eventual interferência (por exemplo, que um serviço está em uma área mais quente do hospital e isso produz medições alteradas da temperatura dos pacientes). Então, não há dúvida de que a previsão seria mais precisa. É exatamente isso que o aplicativo Random Forest faz, conseguindo melhorar a generalização e a precisão. Se o leitor já tem uma ideia do que o Random Forest consegue fazer, podemos fornecer uma explicação um pouco mais técnica.

A Random Forest foi proposta e desenvolvida por Leo Breiman, um estatístico e professor da Universidade da Califórnia em Berkeley. Breiman apresentou a Random Forest em um artigo intitulado “Random Forests” (Breiman 2001). A ideia por trás da Random Forest era abordar problemas de sobreajuste comuns às árvores de decisão individuais e melhorar a precisão e a estabilidade do modelo, combinando várias árvores treinadas de forma independente. Atualmente, o Random Forest está implementado em várias bibliotecas e plataformas de programação. Essas bibliotecas e plataformas permitem que os desenvolvedores utilizem o algoritmo em seus projetos e análises de dados. Atualmente, o Random Forest está presente em alguns dos ambientes e bibliotecas

populares onde há implementações do Random Forest, incluindo: Scikit-learn (Python), R (R Language), Tensor Flow (Python), H2O.ai, Apache Spark MLlib, Weka (Waikato Environment for Knowledge Analysis), etc. Aqui foi utilizado o programa Orange Data Mining 3.37.

Com o Random Forest, podemos *expandir* os 216 resultados da tabela 1 e formar a tabela 3. O gráfico 3.2 a seguir mostra a interface do programa neste caso.

GRÁFICO 3.2. INTERFACE DO ORANGE 3.37 PARA RANDOM FOREST




Fonte: Elaboração própria do Orange Mining

Lembre-se de que, no nosso caso, atribuímos a cada uma das três variáveis independentes os valores 0,0, 0,2, 0,4, 0,6, 0,8 e 1,0. Agora, com o programa, poderemos *prever* o que aconteceria se atribuíssemos os valores 0,00, 0,05, 0,10, 0,15, 0,20, 0,25, 0,30, 0,35, 0,40, 0,45, 0,50, 0,55, 0,60, 0,65, 0,70, 0,75, 0,80, 0,85, 0,90, 0,95, 1,00 a cada variável. Como cada variável tem, então, 21 possibilidades, no total, o programa prevê $21^3 = 9.261$ resultados (valores de α). Poderíamos obter mais, mas não é necessário. Em vez de copiar

a tabela³ com quase dez mil linhas de resultados, apresentaremos uma representação gráfica (gráfico 5).

GRÁFICO 3.3. REPRESENTAÇÃO TRIDIMENSIONAL DOS RESULTADOS DAS EXPERIÊNCIAS AMPLIADAS COM RANDOM FOREST



Fonte: Elaboração própria com Orange Mining

O leitor deve considerar que a figura à direita do gráfico é uma representação bidimensional de uma nuvem de quase 10.000 pontos em três dimensões, à maneira do desenho à esquerda, e que, apesar de uma leve transparência, alguns pontos cobrem outros, pelo que não será possível ver os 9.261 resultados, mas poderá ter uma ideia de como os valores menores (mais azuis e de menor diâmetro nos círculos) e os maiores (mais amarelados e de maior diâmetro) estão dispostos. À primeira vista, pode-se confirmar o que foi dito anteriormente sobre mínimos e máximos: observe que os pontos ficam mais amarelados e de maior diâmetro à medida que avançamos no eixo ϵ .

³ Pode ser baixado em <https://www.uv.es/fjhernan/redes1.xlsx>

4. Construindo a ponte neurodidática (I): neurotransmissores e áreas cerebrais

Chegados a este ponto, em que dispomos da fórmula ideal que relaciona as variáveis, já podemos apresentar a *ponte* que liga essas variáveis da RNA aos *tipos de aprendizagem*, e essa ponte não pode ser outra senão a ação dos neurotransmissores nas diversas áreas cerebrais. E é isso que apresentamos neste epígrafe. Ou seja, dado que as variáveis da RNA *simulam* o comportamento real dos neurotransmissores e a neurologia já demonstrou que estes estão relacionados com os tipos de aprendizagem, podemos *atravessar a ponte* que liga a nossa fórmula à aprendizagem. É importante observar que essa ponte é construída sobre dois pilares diferentes. O primeiro é que as variáveis da RNA *simulam* efetivamente a função dos neurotransmissores que atuam em diversas áreas cerebrais (veremos isso neste tópico). O segundo pilar é que os neurotransmissores e as áreas estão ligados a diferentes tipos de aprendizagem (isso é analisado no próximo tópico).

Na verdade, a justificativa desse primeiro pilar é quase trivial: as RNA são assim chamadas porque *simulam* as redes neurais biológicas. No caso do programa utilizado (chamado precisamente *Simbrain*), os designers explicam como a arquitetura do programa tem precisamente essa função de simulação (Tosi & Yoshimi 2016; Yoshimi et al. 2023) e como a bibliografia já recolhe essa associação das variáveis com os neurotransmissores.

4.1. Variável independente γ

A variável que denominamos “ γ ” e que no programa é designada da mesma forma, corresponde ao parâmetro que a RNA denomina *fator de desconto*. Esse fator determina a orientação para o futuro do agente (da pessoa que aprende). Como já mencionamos, o intervalo é de 0,0 a 1,0. Para valores próximos a 0, o agente se concentra mais nas recompensas imediatas, tem um comportamento *míope* ou impulsivo. Para valores próximos a 1, o agente se concentra mais nas recompensas distantes. O agente

praticamente não aprenderá quando γ for 0, pois só se preocupará com a recompensa imediata e nunca aprenderá a atribuir valor aos estados que conduzem à recompensa.

De uma perspectiva neurocientífica profunda, esse fator de desconto (γ) não é apenas um parâmetro de ajuste algorítmico, mas atua como um análogo matemático da modulação serotoninérgica no córtex pré-frontal e no hipocampo. A serotonina não se limita a estabilizar o estado de humor; é o substrato biológico essencial que permite o adiamento da gratificação, proporcionando a pausa cognitiva necessária para que o sistema priorize objetivos remotos sobre impulsos reativos imediatos.

No modelo aqui apresentado, um valor elevado de γ simula uma rede com alta resiliência e baixa impulsividade, onde as projeções eferentes dos núcleos do rafe garantem que o sinal de erro não desestabilize a arquitetura global do conhecimento diante de contratempos pontuais. Cientificamente, isso se traduz em uma maior “profundidade de campo” cognitiva: o agente — ou o aluno — desenvolve a capacidade de construir uma cadeia causal de longa distância, vinculando ações presentes a consequências futuras. No campo da neurodidática, essa variável representa a base da autorregulação e do pensamento estratégico, demonstrando que, sem uma base de estabilidade serotoninérgica, qualquer tentativa de aprendizagem complexa é sabotada pela urgência do reforço imediato.

Tanaka et al. (2007) já relacionaram o *fator de desconto* com a ação da serotonina no cérebro:

Para elucidar o papel da serotonina na avaliação de recompensas diferidas, realizamos um experimento de imagens cerebrais funcionais no qual os sujeitos escolheram recompensas líquidas pequenas e imediatas ou grandes e diferidas sob regulação dietética de triptofano, um precursor da serotonina. Uma análise baseada em modelos revelou que a atividade da parte ventral do corpo estriado se correlacionava com a previsão de recompensa em escalas de tempo mais curtas, e essa atividade correlacionada era mais intensa com níveis baixos de serotonina. Por outro lado, a atividade da parte dorsal do corpo estriado correlacionou-se com a previsão de recompensa em escalas de tempo mais longas, e essa atividade correlacionada foi mais intensa com níveis elevados de serotonina.

A serotonina (5-HT) atua como um modulador mestre que equilibra a exploração de recursos imediatos em relação à exploração de metas de longo prazo, sendo fundamental para a estabilidade emocional e cognitiva na aprendizagem. Através de suas projeções dos núcleos do rafe para o hipocampo e o córtex pré-frontal, este neurotransmissor regula

a impulsividade e permite que o agente — seja ele biológico ou virtual — mantenha a persistência na ausência de gratificação imediata. Estudos contemporâneos sugerem que níveis ótimos de serotonina facilitam uma “visão de futuro” que protege o sistema do esgotamento metabólico, funcionando como um mecanismo homeostático que previne o estresse cognitivo derivado do excesso de noradrenalina (Cools, Nakamura e Daw, 2011). No contexto neurodidático, essa função a posiciona como o pilar que sustenta a adesão afetiva ao processo educacional.

A serotonina atua por meio de múltiplos receptores (5-HT1A, 5-HT2A, etc.) em áreas como o hipocampo, onde modula a neuroplasticidade, e o córtex pré-frontal. Ela também intervém nos núcleos do rafe, cujos neurônios serotoninérgicos se projetam em múltiplas áreas (uma revisão exaustiva dos efeitos da serotonina pode ser encontrada em Cools, Nakamura e Daw 2011).

4.2. Variável independente δ

A variável δ , que corresponde a um parâmetro da RNA conhecido como *learning rate*, também oscila entre 0,0 e 1,0 e indica a quantidade de pesos que são atualizados em cada passo de tempo. Ela define o tamanho dos passos que são dados para ajustar os pesos sinápticos durante a aprendizagem. Um valor maior permite mudanças mais rápidas, mas pode levar a instabilidades. Um valor menor garante um aprendizado mais estável, mas pode exigir mais iterações para convergir. É usado para equilibrar a velocidade e a precisão do aprendizado. Doya (2007) sugere que isso pode estar relacionado à acetilcolina no cérebro, que regula certas formas de plasticidade. Está ligada ao equilíbrio entre armazenamento na memória e renovação.

A acetilcolina (ACh) atua como um modulador da relação sinal-ruído no córtex, facilitando a codificação de novas informações ao potencializar a entrada de estímulos sensoriais e reduzir a interferência interna. No contexto das RNA, sua função é equiparada à *taxa de aprendizagem*, determinando a magnitude do ajuste nos pesos sinápticos após um erro de previsão. Pesquisas recentes destacam que a ACh é essencial para a transição entre estados de aprendizagem e estados de recuperação da memória, impedindo que memórias antigas bloqueiem a aquisição de novos dados (Hasselmo e Sarter, 2011). Sem uma liberação fásica adequada de acetilcolina no hipocampo, o sistema perderia sua

plasticidade associativa, tornando-se incapaz de atualizar sua “geografia de aprendizagem” diante de mudanças no ambiente.

A acetilcolina atua através de receptores nicotínicos e muscarínicos. No contexto da aprendizagem, os receptores muscarínicos (especialmente o subtipo M1) são cruciais para a plasticidade sináptica, que é a capacidade dos neurônios de modificar a força de suas conexões em resposta a novas experiências.

As áreas-chave da ação da acetilcolina, no que diz respeito à aprendizagem, são também o hipocampo, onde facilita a plasticidade sináptica nesta região, o córtex pré-frontal e os gânglios basais, nos quais permite a coordenação e execução de movimentos.

4.3. Variável independente ϵ

A variável ϵ , que corresponde a um parâmetro homônimo da RNA, determina a magnitude do ajuste realizado nos pesos sinápticos em cada iteração. Um valor maior de ϵ implica mudanças maiores nos pesos, enquanto um valor menor produz ajustes menores e mais precisos; por isso, representa a probabilidade de realizar uma ação aleatória. O valor 0,0 está associado a nenhuma probabilidade, ou seja, à impossibilidade de uma ação aleatória; o valor 1,0 representaria o caso em que todas as ações seriam aleatórias. Doya (2002, 2007) sugeriu que isso poderia estar relacionado à noradrenalina (ou norepinefrina), que regula a ativação geral (diminui durante o sono, aumenta ao acordar, etc.). Em outros termos, a noradrenalina regula o equilíbrio entre exploração ampla e execução focada.

A noradrenalina, liberada principalmente a partir do *locus coeruleus*, regula o compromisso do agente com seu ambiente, oscilando entre a exploração de recursos conhecidos e a exploração de novas possibilidades. Níveis moderados desse neurotransmissor otimizam a eficácia do processamento neuronal, mas um excesso — biologicamente associado ao estresse — induz uma exploração errática que desestabiliza a aprendizagem. Como aponta a teoria do ganho adaptativo, a noradrenalina atua como um interruptor que permite ao sistema “reiniciar” suas conexões diante de uma queda inesperada no desempenho (Aston-Jones e Cohen, 2005). Nos modelos SNN, esse

fenômeno é observado quando um valor alto de ϵ dispara as iterações, simulando um estado de estresse cognitivo que bloqueia a rede e penaliza drasticamente a eficiência.

A noradrenalina atua por meio de receptores adrenérgicos (α e β – não confundir com o uso anterior dessas letras gregas como variáveis de nossos experimentos –) em áreas como a amígdala, o hipocampo e o locus coeruleus. Também no córtex pré-frontal. Em situações de estresse ou perigo, o locus coeruleus libera norepinefrina, que aumenta o estado de alerta e facilita a consolidação de memórias emocionais. A norepinefrina aumenta a excitabilidade neuronal e modula a plasticidade sináptica.

Portanto, o primeiro *pilar* para construir nossa ponte pode ser sintetizado na tabela 6 a seguir.

TABELA 4.1. RELAÇÃO DE VARIÁVEIS DOS EXPERIMENTOS, PARÂMETROS DAS RNA, NEUROTRANSMISSORES E ÁREAS CEREBRAIS

Variável Tabela 1	Parâmetro RNA	Neurotransmissor	Área cerebral
γ	γ (desconto)	Serotonina	Hipocampo e córtex pré-frontal
δ	Aprendizagem rt.	acetilcolina	Hipocampo, córtex pré-frontal e gânglios basais
ϵ	ϵ	noradrenalina	Locus coeruleus, amígdala, córtex pré-frontal

Fonte: elaboração própria.

Agora explicaremos os resultados. Em primeiro lugar, a diferença entre o modelo absoluto e o restrito, começando por este.

O modelo absoluto (sem restrições) tem um significado neurológico claro: representa o potencial neuroquímico bruto. Neste modelo, tratamos a serotonina (γ), a noradrenalina (ϵ) e a acetilcolina (δ) como variáveis independentes que podem subir ou descer sem um limite de soma. Isso simula estados de suplementação externa ou patologia. Por exemplo, quando se administra um medicamento que eleva um neurotransmissor sem que os outros necessariamente diminuam, ou em situações de estresse extremo em que o cérebro “rompe” seus limites normais de segurança. Isso representa, mais ou menos, um mundo ideal: se pudéssemos injetar a quantidade exata de cada substância química, qual seria o custo de aprendizagem ideal? Em nosso estudo, o sistema é capaz de baixar até $\alpha \approx 1.022$

iterações (987 com restrição). É a “velocidade máxima” do motor de aprendizagem em nosso experimento e vemos como a serotonina é potente.

O modelo restrito (as variáveis somam 1) possui outro significado neurológico: representa a economia metabólica e a homeostase. Este é o modelo mais realista para a aprendizagem cotidiana. O cérebro possui um “orçamento” limitado de energia, precursores de aminoácidos e espaço nos transportadores sinápticos. Se decidir dedicar mais recursos para estar alerta (noradrenalina), necessariamente terá que subtrair recursos da calma (serotonina) ou da associação (acetilcolina). Portanto, este modelo simula a estratégia de aprendizagem de um indivíduo real: não podemos ser 100% emocionais, 100% lógicos e 100% alertas ao mesmo tempo. O cérebro deve escolher um “perfil” ou equilíbrio. A questão agora é: dado que o cérebro é um sistema limitado, qual é a melhor distribuição de recursos para não ficar bloqueado? O resultado da nossa experiência é uma espécie de proporção áurea (0,49 / 0,31 / 0,00).

A chave está na passagem do modelo absoluto para o restrito: a serotonina perde um pouco de peso (de 0,49 para 0,45) para permitir que as outras duas variáveis “sobrevivam”. Neurologicamente, isso significa que o aprendizado ideal não é simplesmente “muita serotonina”, mas que a serotonina deve ser alta o suficiente para proteger o sistema, mas não tanto a ponto de “abafar” o sinal de alerta da noradrenalina ou a lógica da acetilcolina. O modelo absoluto nos diz qual neurotransmissor é mais forte, mas o restrito nos diz como eles devem coexistir para que a aprendizagem seja sustentável. No entanto, podemos avançar ainda mais porque, como já foi sugerido no texto anterior, os neurotransmissores estão relacionados a *tipos* de aprendizagem. Chegamos assim ao segundo pilar da nossa ponte neurodidática.

4.4. Células gliais (astrócitos e microglia)

Embora a experimentação tenha buscado a “proporção áurea” dos neurotransmissores, em um cérebro biológico, é preciso acrescentar que essa proporção é mantida pela glia. Sem a intervenção dos *astrócitos* para limpar o excesso de neurotransmissores ou metabolizá-los, o sistema atingiria o estado de “saturação” ou “excitotoxicidade” muito antes do previsto nas simulações.

Os astrócitos são as células responsáveis por gerenciar precisamente essas substâncias, como a serotonina, a acetilcolina e a noradrenalina, que modulam a aprendizagem no espaço sináptico. Os astrócitos liberam e reabsorvem (*reuptake*) neurotransmissores, além de metabolizá-los e desintoxicá-los. Isso significa que o “orçamento metabólico” que mencionamos no modelo restrito ($\gamma + \delta + \epsilon = 1$) é fisicamente controlado pela atividade dos astrócitos, que garantem que os níveis desses químicos sejam ótimos para o funcionamento cerebral. De acordo com Schmidgall et al. (2024), os astrócitos têm uma influência notável nas mudanças estruturais da força sináptica. Assim, por exemplo, a microglia desempenha tarefas de reparação e modulação. Participam na reparação do tecido danificado, o que é vital para manter a integridade dos circuitos de memória a longo prazo, e na modulação de sinais; tal como os astrócitos, a microglia também modula a sinalização dos neurotransmissores, atuando como um sistema de manutenção que garante que a aprendizagem não seja degradada por “ruído” ou danos na rede.

5. Construindo a ponte neurodidática (II): A ação dos neurotransmissores em áreas cerebrais está relacionada com tipos de aprendizagem

5.1. Introdução: Rumo a uma taxonomia integradora da aprendizagem

A compreensão de como os seres humanos aprendem tem sido um dos objetos de estudo mais duradouros na história da pedagogia e da psicologia educacional. Desde as primeiras reflexões filosóficas de Platão sobre a reminiscência até as sofisticadas modelagens computacionais contemporâneas, o esforço para desvendar os mecanismos da aprendizagem gerou múltiplas taxonomias, teorias e modelos explicativos. No entanto, grande parte dessas classificações tradicionais operou a partir de paradigmas disciplinares isolados, gerando uma fragmentação epistemológica que dificulta a transferência de conhecimento entre a neurociência, a psicologia cognitiva e a prática docente.

O segundo pilar da ponte que nos permite transitar da experiência com RNA e do cálculo da fórmula ótima da aprendizagem é, logicamente, a associação dos neurotransmissores e suas áreas de ação com tipos de aprendizagem e, em última análise, com as três formas que mencionamos provisoriamente no início: a *aprendizagem afetiva/adesiva*, a *associativa* e a *aversiva/defensiva*. Ao fazer isso, podemos integrar o discurso pedagógico ou a reflexão didática, mas não argumentar apenas dentro desses campos.

Essa tripartição, emergente das experiências com redes neurais artificiais (RNA) descritas nos capítulos anteriores, não constitui uma mera categorização teórica, mas uma ferramenta operacional fundamentada na economia metabólica cerebral e validada por modelos computacionais de homeostase neuroquímica ($\gamma + \delta + \varepsilon = 1$). A relevância desta proposta reside na sua capacidade de transcender a dicotomia entre a “aprendizagem emocional” e a “aprendizagem cognitiva” — frequentemente apresentada como uma oposição excludente na tradição pedagógica — para compreender que ambos os processos são manifestações complementares de um mesmo sistema de otimização de recursos neuronais.

Como demonstram nossos experimentos com RNA, a eficiência máxima da aprendizagem (número mínimo de iterações $\alpha \approx 367$) é alcançada quando a serotonina (γ

= 0,331), a acetilcolina ($\delta = 0,534$) e a noradrenalina ($\varepsilon = 0,135$) operam em proporção homeostática, configurando o que denominamos de ***“proporção áurea” da aprendizagem** ($\delta \approx 1/2$; $\gamma \approx 1/3$; $\varepsilon \approx 1/6$).

5.2. Os três tipos de aprendizagem: definição e fundamentação teórica

5.2.1. Aprendizagem afetiva ou adesiva

A aprendizagem afetiva, também denominada *adesiva* em nossa nomenclatura neurocomputacional, é definida como o processo pelo qual os indivíduos estabelecem vínculos emocionais duradouros com objetos, pessoas, ideias ou contextos de aprendizagem, gerando uma “adesão” que transcende a mera associação cognitiva para implicar compromisso, identificação e senso de pertencimento. Ao contrário do condicionamento clássico — que opera por meio de associações estímulo-resposta — ou da aprendizagem por reforço — que depende de consequências contingentes —, a aprendizagem afetiva é caracterizada por sua *autonomia motivacional*: o sujeito persiste no processo educacional mesmo na ausência de gratificação imediata, movido por uma projeção para o futuro que transforma o esforço presente em um investimento significativo.

Na tradição pedagógica, esse tipo de aprendizagem tem suas raízes na *teoria do apego* de John Bowlby (1969/1982), que demonstrou que os laços emocionais precoces constituem a base de toda exploração posterior do ambiente. No âmbito educacional, essa perspectiva foi desenvolvida por Carl Rogers (1961) por meio de sua concepção de “aprendizagem experiencial significativa”, que postula que o conhecimento adquire relevância quando se vincula à autoconceituação do aluno e seus projetos de vida. Rogers distinguia entre aprendizagem “do pescoço para cima” — meramente cognitiva e transitória — e aprendizagem “envolvida” — que envolve os sentimentos, as atitudes e a totalidade da pessoa —, antecipando a distinção contemporânea entre aprendizagem superficial e profunda (Marton & Säljö, 1976).

A teoria da autodeterminação de Deci e Ryan (1985, 2017) fornece uma estrutura robusta para compreender as dinâmicas da aprendizagem afetiva. Segundo esses autores, a

motivação intrínseca — o protótipo da aprendizagem adesiva — surge quando três necessidades psicológicas básicas são satisfeitas: *autonomia* (sentido de voluntariedade na ação), *competência* (percepção de eficácia) e *relação* (conexão significativa com os outros). Nossos experimentos com RNA corroboram essa tripartição a partir de uma perspectiva neurocomputacional: a variável γ (serotonina) opera precisamente como a “âncora” que permite ao sistema manter a orientação para metas distantes (visão de futuro), satisfazendo a necessidade de autonomia por meio do adiamento da gratificação imediata (Cools, Nakamura & Daw, 2011).

Na tradição da pedagogia crítica, Paulo Freire (1970) enfatizou a dimensão afetiva da aprendizagem por meio de seu conceito de “conscientização”, que implica não apenas a compreensão intelectual da realidade, mas um compromisso existencial com sua transformação. Para Freire, a aprendizagem genuína é “aprendizagem dialogante”, onde o afeto e a razão se fundem em um processo de humanização mútua. Essa perspectiva ecoa nossas descobertas sobre a função da serotonina na coesão social e na persistência diante de tarefas complexas: sem o suporte γ , o sistema — seja ele biológico ou artificial — sucumbe à “miopia comportamental”, sendo incapaz de valorizar recompensas futuras.

· *Relação com a serotonina e a pedagogia*

A serotonina está associada à regulação do humor, da ansiedade e do comportamento social. A aprendizagem adesiva ou afetiva, que envolve a formação de laços emocionais e sociais, é fortemente influenciada por esse neurotransmissor. No caso da serotonina, estudos experimentais (com ratos e humanos) e modelos computacionais evidenciam sua relação com as dinâmicas de aprendizagem por adesão. Estudos demonstraram que a diminuição dos níveis de serotonina está associada a dificuldades na formação de laços sociais e na aprendizagem afetiva (Young & Leyton, 2002). Luo et al. (2024:600) também afirmam que os resultados apoiam um papel da serotonina na flexibilidade e plasticidade do comportamento, indicado, respectivamente, por aumentos ou diminuições na repetição de escolhas (“aderência” [stickiness]) ou nas taxas de aprendizagem de reforço após manipulações destinadas a aumentar. Da mesma forma, “as evidências translacionais convergentes indicam um papel da serotonina na modulação dos parâmetros de ação de seleção, afeto e cognição social, dependendo do contexto; e, ao mesmo tempo, apoiam os mecanismos de aprendizagem, que promovem a adaptabilidade e a flexibilidade comportamental” (Clark, Sahakian & Robbins, 2020:1).

Michely et al. (2020), que realizaram pesquisas com modelos computacionais, chegam a uma conclusão semelhante, de que a serotonina está envolvida na modulação da dinâmica da aprendizagem afetiva, o que permite explicar que “a modulação da dinâmica da aprendizagem afetiva pode explicar a evolução de uma melhora gradual do humor ao longo do tempo” (Michely et al., 2020).

Na aprendizagem adesiva, a serotonina facilita a formação de conexões positivas entre indivíduos, por exemplo, por meio da recompensa social. Isso se deve em parte à sua interação com a dopamina, um neurotransmissor fundamental nos sistemas de recompensa (Young & Leyton, 2002).

Além da serotonina, devemos levar em consideração a dopamina. No contexto da Rede Neural Artificial e do modelo Ator-Crítico, a dopamina funciona como o sinal de erro de previsão de recompensa; é o mecanismo que “paga” à rede cada vez que uma ação aproxima o rato do queijo, permitindo que os pesos sinápticos sejam ajustados e as rotas bem-sucedidas sejam consolidadas. Sem esse impulso dopaminérgico, o sistema não teria um critério para distinguir um movimento útil de um errático, e a eficiência (medida em suas iterações α) não melhoraria com as tentativas (Schultz, 2016).

5.2.2. Aprendizagem associativa

A aprendizagem associativa constitui o mecanismo fundamental pelo qual o sistema nervoso estabelece conexões entre estímulos, respostas e consequências, formando representações internas do ambiente que permitem prever e controlar os acontecimentos. Ao contrário da aprendizagem afetiva — que opera por meio de vínculos de avaliação —, a associativa é caracterizada por sua *precisão técnica*: trata-se de ajustar os “pesos” das conexões neuronais para minimizar o erro de previsão e maximizar a eficiência do processamento de informações.

A tradição pedagógica da aprendizagem associativa tem suas origens no *associacionismo* do Iluminismo — de Locke a Hume —, que concebia a mente como uma “tábula rasa” onde as ideias se formavam por meio da contiguidade temporal das impressões sensoriais. No século XX, essa tradição foi sistematizada pelo *condicionismo* de Pavlov, Watson e Skinner, que demonstraram experimentalmente que o comportamento podia ser

modificado através do controle de contingências estímulo-resposta-reforço. No entanto, o condicionismo clássico, ao negar a relevância dos processos internos, revelou-se insuficiente para explicar a aprendizagem complexa em humanos.

A teoria do processamento da informação, desenvolvida por Atkinson e Shiffrin (1968) e posteriormente refinada por Baddeley (1986) por meio de seu modelo de memória de trabalho, representou uma virada cognitivista fundamental. De acordo com essa perspectiva, a aprendizagem associativa envolve a codificação, o armazenamento e a recuperação de informações por meio de estruturas esquemáticas que organizam o conhecimento. David Ausubel (1968) introduziu a distinção crucial entre aprendizagem mecânica (associações arbitrárias) e aprendizagem significativa (subsunção de novas informações em estruturas cognitivas pré-existentes), postulando que a verdadeira aprendizagem requer a ativação de “organizadores prévios” que conectem o novo com o conhecido.

Nessa linha, Jerome Bruner (1961, 1966) desenvolveu sua teoria da aprendizagem por descoberta, que — ao contrário do que costuma ser interpretado — não implica uma mera exploração livre, mas um processo estruturado de hipóteses e verificação guiado pelo professor. Bruner distinguia três modos de representação do conhecimento: encetivo (ação), icônico (imagem) e simbólico (linguagem), postulando que a aprendizagem associativa ideal progride sequencialmente por esses níveis. Essa hierarquização ressoa com nossa conceituação da acetilcolina (δ) como moduladora da “relação sinal-ruído”: em cada nível representacional, o sistema deve filtrar as informações irrelevantes para consolidar associações estáveis.

A teoria da carga cognitiva de John Sweller (1988, 2011) fornece diretrizes instrucionais cruciais para a aprendizagem associativa. Sweller distingue entre carga intrínseca (determinada pela complexidade do material), carga extrínseca (gerada por um design instrucional inadequado) e carga germinativa (dedicada à construção de esquemas). Nossos experimentos com RNA validam empiricamente essa distinção: quando a variável δ (acetilcolina) opera em níveis ótimos ($\approx 0,534$), o sistema reduz drasticamente a “carga extrínseca” — o ruído sináptico — permitindo uma rápida convergência para a solução correta. Por outro lado, quando δ é insuficiente, o sistema entra em “vagabundagem cognitiva”, aumentando exponencialmente o número de iterações necessárias.

Relação com a acetilcolina e a pedagogia

No que diz respeito à acetilcolina, a bibliografia científica já registra há anos a relação com a aprendizagem (associativa). Podemos mencionar as pesquisas de Michael E. Hasselmo (1993 — criticado em Blockland, 1995, que mantém, no entanto, o papel do neurotransmissor na atenção — e 2006), que relacionou esse neurotransmissor com a aprendizagem associativa e lhe atribuiu um papel de destaque na supressão de interferências (dissonâncias cognitivas): “Aqui proponho – escreve Hasselmo – que os efeitos da acetilcolina nas estruturas corticais podem fornecer um mecanismo neuropsicológico para essa fixação [clamping]” (1993: resumo; ver Neurobiologia, 2003). Este clamping não deve ser confundido com o chamado fechamento categórico na teoria dos sistemas (por exemplo, em N. Luhmann) e deve ser melhor relacionado com a noção clássica de dissonância cognitiva, formulada por Leon Festinger em 1957. Tem a ver com a redução da tensão que se experimenta quando se resolve um problema. Existe uma longa tradição de didáticas problemáticas (ou problemáticas), por problemas, por projetos, etc., que, em definitiva, pretendem, com abordagens holísticas, levar o indivíduo a realizar esse fechamento e suprimir as interferências do conhecimento.

Quando ocorre uma dissonância cognitiva, a acetilcolina é liberada em áreas como o hipocampo e o córtex pré-frontal. Essa liberação facilita a potenciação de longo prazo (LTP, Long-Term Potentiation), um processo que reforça as conexões neuronais e permite a formação de novas memórias. A acetilcolina também inibe a atividade de neurônios que poderiam interferir no processo de aprendizagem, ajudando a suprimir informações irrelevantes ou contraditórias. Foi demonstrado que a diminuição dos níveis de acetilcolina no córtex pré-frontal está associada a dificuldades para resolver conflitos cognitivos (Hasselmo & Sarter, 2011).

Um estudo recente (González-Redondo et al., 2025) propõe que a acetilcolina atua como uma “porta temporária” que permite que a dopamina ajuste finamente a aprendizagem. Portanto, como vimos, as variáveis devem estar equilibradas. Schmidgall et al. (2024) também propõem uma revisão de como integrar os mecanismos biológicos da dopamina ou da serotonina nas redes neuronais artificiais.

5.2.3. Aprendizagem aversiva ou defensiva

A aprendizagem aversiva, também denominada *defensiva* em nossa terminologia, é definida como o processo pelo qual os organismos adquirem comportamentos orientados para evitar ou escapar de estímulos nocivos, perigosos ou ameaçadores. Ao contrário da aprendizagem por reforço positivo — que busca a aproximação de metas desejáveis —, a aversiva opera por meio da *minimização do dano potencial*, configurando um sistema de alerta e proteção que é conservado evolutivamente e neurobiologicamente prioritário.

A tradição pedagógica da aprendizagem aversiva tem uma genealogia complexa, pois historicamente tem sido associada a práticas educativas autoritárias baseadas no castigo e na coerção. No entanto, de uma perspectiva científica contemporânea, a aprendizagem aversiva constitui um mecanismo adaptativo fundamental que — quando compreendido e dosado adequadamente — pode potencializar a resiliência, a autorregulação e a capacidade de aprendizagem em condições de incerteza.

O *condicionismo* de Skinner (1938, 1953) sistematizou experimentalmente a aprendizagem aversiva por meio da análise do condicionamento operante, distinguindo entre reforço negativo (aumento do comportamento por meio da eliminação de um estímulo aversivo) e punição (diminuição do comportamento por meio da apresentação de um estímulo aversivo). No entanto, a crítica humanista à “tecnologia do comportamento” levou a uma demonização da aprendizagem aversiva na pedagogia progressista, perdendo-se de vista sua função protetora e adaptativa.

A teoria de Manu Kapur (2008, 2014, 2016) representa uma reconceitualização pedagógica fundamental da aprendizagem aversiva. Kapur demonstra experimentalmente que o desenho intencional de situações de “falha inicial” — problemas complexos que os alunos não conseguem resolver imediatamente — gera condições ótimas para a aprendizagem profunda, desde que posteriormente seja fornecida instrução direta que permita “montar” o conhecimento. Este paradigma, validado em múltiplas meta-análises (Kapur, 2016), demonstra que a experiência controlada de dificuldade e frustração — o que no nosso modelo corresponde a uma ativação moderada da noradrenalina (ϵ) — prepara o sistema cognitivo para uma consolidação posterior mais robusta.

A partir da neuroeducação, a conceituação do estresse como *eustresse* (desafio) versus *distresse* (ameaça) permite distinguir entre uma ativação aversiva adaptativa e uma patológica. Segundo McGonigal (2015), a reinterpretação do estresse como “sinal do corpo que nos prepara para o desafio” transforma a resposta fisiológica: em vez de

vasoconstrição e medo, ocorre uma ativação cardiovascular que facilita o desempenho. Nossas experiências com RNA confirmam essa curva em forma de U invertido: níveis moderados de ε ($\approx 0,135$) otimizam a aprendizagem, enquanto valores superiores a 0,40 geram “colapso cognitivo” por saturação dos receptores adrenérgicos.

Relação com a noradrenalina e a pedagogia

No caso da norepinefrina ou noradrenalina, ela está ligada a respostas emocionais como medo, estresse e ansiedade. Este neurotransmissor é fundamental na aprendizagem aversiva, que envolve associar estímulos a resultados negativos ou perigosos. Embora esteja relacionado com a exploração aleatória (que pode ser devida à mudança ou ao stress), existem estudos que mostram a relação entre este neurotransmissor e uma aprendizagem aversiva, modulada pela experiência (Stanley et al., 2023). Essa aprendizagem aversiva, de acordo com a neurologia, poderia estar relacionada à aprendizagem defensiva, tal como definida pelo psicólogo social Klaus Holzkamp (ver Holzkamp, 1995; Arnold & Holzkamp, 2009). Trata-se da aprendizagem que fazemos para evitar algo desagradável. Embora evitemos dar exemplos, os textos de Holzkamp referem-se, por exemplo, à preparação para um exame para evitar a reprovação.

Na aprendizagem aversiva, a noradrenalina reforça as conexões entre a amígdala (responsável pelo processamento das emoções) e o hipocampo (responsável pela formação das memórias). Isso permite que as experiências negativas sejam melhor lembradas para evitar perigos futuros. Estudos em animais demonstraram que o bloqueio dos receptores adrenérgicos impede a aprendizagem aversiva (Sara, 2009).

É importante acrescentar que, de acordo com Stanley et al. (2023), a noradrenalina é o interruptor da “plasticidade” diante da incerteza, validando a ideia aqui exposta de que essa variável controla a exploração da novidade.

5.3. Aplicações didáticas por áreas curriculares e níveis educacionais

A operacionalização dos três tipos de aprendizagem no projeto instrucional requer a consideração das especificidades disciplinares e do desenvolvimento cognitivo dos alunos. A seguir, apresentamos exemplos contextualizados para o Ensino Fundamental e Médio nas áreas de Matemática, Ciências Naturais e Línguas.

5.3.1. Matemática

Ensino Fundamental (6-12 anos)

Aprendizagem afetiva/adesiva ($\gamma \approx 33\%$):

O desenvolvimento de uma “identidade matemática” positiva constitui a base de toda competência numérica posterior. De acordo com Boaler (2019), a crença de “não ser bom em matemática” é estabelecida precocemente por meio de mensagens sociais e experiências de fracasso humilhante. O projeto instrucional deve priorizar a criação de um “clima de segurança” onde o erro seja reinterpretado como “resolução em processo”. Estratégias concretas incluem: (a) rotinas de “número do dia” onde todos os alunos contribuem com observações válidas, construindo coletivamente o sentido numérico; (b) narrativas matemáticas que relacionam problemas com situações significativas para os alunos (planejamento de festas, viagens, projetos comunitários); e (c) avaliação formativa por meio de “notas de admiração” que destacam o processo de raciocínio mais do que o resultado correto.

Aprendizagem associativa ($\delta \approx 53\%$):

A construção da fluência operacional requer precisão técnica e prática deliberada. Seguindo Hattie (2009), o “feedback imediato” é a intervenção docente de maior impacto na aprendizagem matemática. No ensino fundamental, isso se concretiza em: (a) manipulativos estruturados (régua de Cuisenaire, ábaco, blocos base-10) que fornecem feedback tangível sobre a correção dos procedimentos; (b) algoritmos visuais e verbais que conectam a ação física com a representação simbólica; e (c) “microaulas” de 10 a 15 minutos com objetivos milimétricos (por exemplo, “hoje vamos aprender a reagrupar na subtração quando o minuendo tem um zero”), seguindo o modelo de Engelmann e Colvin (2006) de Instrução Direta.

Aprendizagem aversiva/defensiva ($\epsilon \approx 13\%$):

A introdução controlada de “dificuldades desejáveis” (Bjork & Bjork, 2011) fortalece a retenção e a transferência.

No ensino fundamental, o “fracasso produtivo” é implementado por meio de: (a) problemas de “início aberto”, nos quais os alunos geram múltiplas estratégias antes que

o professor apresente o algoritmo convencional; (b) “erros planejados”, nos quais o professor apresenta soluções incorretas que os alunos devem detectar e corrigir; e (c) jogos matemáticos com regras variáveis que exigem flexibilidade cognitiva. O segredo é manter a proporção ε dentro da faixa eustress ($\approx 0,135$), evitando a ansiedade matemática que bloqueia o acesso à memória de trabalho (Ashcraft & Kirk, 2001).

Ensino médio (12-16 anos)

Aprendizagem afetiva/adesiva:

Na adolescência, a motivação intrínseca frequentemente diminui diante da pressão das avaliações externas. A aprendizagem-serviço (ApS) constitui uma estratégia poderosa para reconectar a matemática com o propósito pessoal e social. Exemplos incluem: modelagem matemática de problemas locais (otimização de rotas de coleta de lixo, análise estatística de dados sociais), projetos de “ciência cidadã” onde os alunos contribuem para pesquisas reais e mentoria entre pares, onde os alunos mais avançados orientam seus colegas, fortalecendo sua própria identidade matemática (Ryan & Deci, 2017).

Aprendizagem associativa:

A transição para o pensamento algébrico requer a consolidação de esquemas abstratos por meio da “variedade de prática” (Rohrer, 2012). As estratégias incluem: (a) espaçamento intercalado de problemas de diferentes tipos (em vez de blocos monotemáticos); (b) “prática de recuperação” (retrieval practice) por meio de questionários de baixo impacto que fortalecem as vias de acesso à memória de longo prazo; e (c) uso de software de álgebra computacional (GeoGebra, Desmos) que fornece feedback imediato sobre a correção de procedimentos simbólicos, permitindo que a variável δ opere em tempo real.

Aprendizagem aversiva/defensiva:

A resolução de problemas complexos do tipo PISA (níveis 4-6) requer tolerância ao “impasse” cognitivo. O professor deve projetar “pontes de frustração”: problemas que os alunos não conseguem resolver com suas ferramentas atuais, mas cuja estrutura antecipa os conceitos que serão introduzidos posteriormente. Por exemplo, apresentar problemas de otimização antes de ensinar cálculo diferencial ou problemas complexos de contagem antes de combinatórias formais. A intervenção posterior do professor deve “montar” as intuições geradas durante a fase de exploração fracassada, seguindo a sequência: ativação → consciência da lacuna → afeto de resolução → montagem (Kapur, 2016).

5.3.2. Ciências Naturais

Ensino Fundamental

Aprendizagem afetiva/adesiva:

A “maravilha científica” e o senso de admiração constituem o motor inicial da curiosidade natural (Dehaene, 2019). As estratégias incluem: (a) “rotinas de pensamento científico” (Chalk Talk, See-Think-Wonder) que legitimam a pergunta e a especulação; (b) conexão com fenômenos locais e cotidianos (por que se formam as nuvens? como as plantas crescem no nosso quintal?) antes de abstrair princípios gerais; e (c) visitas a espaços naturais onde o vínculo emocional com o ambiente motive a investigação sistemática posterior.

Aprendizagem associativa:

A construção de modelos mentais corretos requer a confrontação explícita com concepções alternativas. Seguindo Posner et al. (1982), a mudança conceitual implica: (a) desequilíbrio (confrontação com anomalias que a concepção anterior não pode explicar); (b) inteligibilidade (a nova concepção deve ser compreensível); (c) plausibilidade (deve ser mais crível que a anterior); e (d) fertilidade (deve ser frutífera para novas previsões). O professor deve fornecer uma “estrutura cognitiva” que guie essa transição, utilizando analogias controladas, simulações visuais e previsão-observação-explicação (POE).

Aprendizagem aversiva/defensiva:

As “experiências fracassadas” — em que o resultado não coincide com a previsão — constituem oportunidades de aprendizagem superiores às experiências bem-sucedidas. O professor deve normalizar o “não sei” e o “não funcionou”, criando um “banco de erros” da turma onde são documentadas as previsões incorretas e suas possíveis explicações. A prática da “argumentação científica” — defender uma posição com evidências, reconhecer suas limitações e revisá-la diante de novas informações — desenvolve a resiliência epistêmica necessária para a prática científica autêntica.

Ensino Médio

Aprendizagem afetiva/adesiva:

A participação em projetos de pesquisa autênticos (ciência cidadã, feiras de ciências, olimpíadas) fortalece a identidade científica. A conexão com cientistas reais por meio de programas de mentoria virtual e a exposição à “história da ciência” com seus fracassos e controvérsias humanizam a prática científica e a tornam inspiradora.

Aprendizagem associativa:

A compreensão de teorias complexas (teoria cinética, evolução, genética) requer a integração de múltiplas representações (macroscópica, microscópica, simbólica, matemática). O professor deve fornecer “pacotes de tradução” que conectem explicitamente esses níveis e utilizar “organizadores gráficos avançados” (mapas de sistemas, ciclos de retroalimentação) que externalizem as relações causais complexas.

Aprendizagem aversiva/defensiva:

O debate científico sobre temas controversos (mudança climática, biotecnologia, energia nuclear) requer tolerância à incerteza e capacidade de rever posições diante de novas evidências.

O “jogo de papéis científicos”, em que os alunos defendem diferentes posições teóricas históricas (por exemplo, corpuscular vs. ondulatória), desenvolve a flexibilidade epistêmica e a compreensão de que o conhecimento científico é provisório e revisável.

5.3.3. Línguas (língua materna e segundas línguas)

Ensino Fundamental

Aprendizagem afetiva/adesiva:

O desenvolvimento da “identidade leitora” e da “identidade escritora” é prioritário. As estratégias incluem: (a) “tempo de leitura prazerosa” (Drop Everything And Read), em que os alunos escolhem livros de seu interesse sem avaliação posterior; (b) “círculos de leitura” que constroem uma comunidade em torno de textos compartilhados; e (c)

publicação de textos autênticos (jornal escolar, blog da turma, correspondência com outras escolas) que conferem um propósito comunicativo real à escrita.

Aprendizagem associativa:

O ensino explícito de ortografia, gramática e estrutura textual por meio de “mini-aulas” (Calkins, 2001) que são aplicadas imediatamente em contextos de escrita autêntica. O uso de “rubricas de análise” que decompõem textos modelo em seus componentes, permitindo que os alunos “imitam” estruturas eficazes em seus próprios textos.

Aprendizagem aversiva/defensiva:

A “escrita em zonas de risco” — gêneros desconhecidos, públicos desafiadores, temas controversos — desenvolve a flexibilidade retórica. O “teatro de erros”, onde os alunos encenam diálogos com erros gramaticais ou pragmáticos que o público deve detectar, transforma a correção em uma atividade lúdica.

Ensino médio

Aprendizagem afetiva/adesiva:

A literatura como “experiência vivida” (Rosenblatt, 1978) requer uma conexão pessoal com textos clássicos e contemporâneos. As estratégias incluem: “diários de dupla entrada” que combinam citações textuais com respostas pessoais; adaptações criativas de textos canônicos a contextos atuais; e projetos de “literatura e sociedade” que exploram como os textos literários esclarecem problemas contemporâneos.

Aprendizagem associativa:

A análise retórica e a argumentação formal requerem o ensino explícito de estruturas (Toulmin, Aristóteles) por meio da “decomposição de textos” e da “reconstrução guiada”. A prática deliberada de múltiplas revisões, com feedback específico sobre aspectos concretos (clareza, evidência, conexões lógicas) em cada iteração.

Aprendizagem aversiva/defensiva:

A escrita em “gêneros desconhecidos” (ensaio filosófico, artigo de opinião jornalística, roteiro cinematográfico) sem modelo prévio, seguida de análise comparativa com modelos canônicos, desenvolve a consciência metalinguística e a adaptabilidade retórica.

5.4. Bases neurocientíficas: Da ponte neurodidática à homeostase da aprendizagem

A articulação dos três tipos de aprendizagem com seus substratos neurobiológicos constitui a contribuição original deste relatório, validada por meio de experimentação com RNA e SNN (Redes Neurais de Impulsos).

5.4.1. Serotonina ($\gamma = 0,331$) e a aprendizagem afetiva/adesiva

A serotonina (5-HT) modula a função dos circuitos pré-frontais e hipocampais que estão na base da regulação emocional, da tomada de decisões a longo prazo e da coesão social (Cools, Nakamura & Daw, 2011). De uma perspectiva computacional, a serotonina implementa o “fator de desconto temporal” (γ) que determina quanto valor o agente atribui às recompensas futuras em comparação com as imediatas.

Tanaka et al. (2007) demonstraram por meio de neuroimagem que a depleção de triptofano (precursor da serotonina) reduz a atividade do estriado dorsal associada à previsão de recompensas diferidas, aumentando simultaneamente a atividade do estriado ventral associada à gratificação imediata. Isso explica por que níveis baixos de γ (serotonina) geram “miopia comportamental”: o sistema é incapaz de persistir em tarefas que exigem esforço sustentado sem recompensa imediata.

No contexto educacional, isso implica que o clima de segurança emocional e o senso de pertencimento não são meros “condicionantes” da aprendizagem, mas variáveis que modulam diretamente a capacidade do sistema de manter a orientação para metas educacionais distantes. A serotonina fornece a “infraestrutura temporal” que permite que o esforço presente seja sustentado pela projeção futura.

5.4.2. Acetilcolina ($\delta = 0,534$) e a aprendizagem associativa

A acetilcolina (ACh) é o principal neuromodulador da atenção seletiva, da plasticidade sináptica e da memória episódica (Hasselmo & Sarter, 2011). No córtex cerebral, a ACh

aumenta a “relação sinal-ruído” por meio de dois mecanismos complementares: (a) potencialização da resposta a estímulos aferentes relevantes e (b) supressão da atividade de fundo e estímulos irrelevantes.

Doya (2002, 2007) propôs que a ACh implementa computacionalmente a “taxa de aprendizagem” (δ) em modelos de reforço: níveis elevados de ACh permitem atualizações rápidas dos pesos sinápticos diante de novas informações, enquanto níveis baixos mantêm a estabilidade das representações pré-existentes. Nossos experimentos com RNA confirmam que $\delta = 0,534$ constitui o ótimo para a convergência rápida: suficientemente alto para permitir o ajuste fino de associações, mas não tanto a ponto de gerar instabilidade.

A acetilcolina também regula a transição entre modos de codificação (aprendizado de novas informações) e modos de recuperação (acesso à memória consolidada). Essa função é crítica para evitar o “esquecimento catastrófico” — a perda de informações anteriores diante de novos aprendizados — que caracteriza as RNA artificiais tradicionais e que a neurogênese hipocampal parece resolver em sistemas biológicos (Schmidgall et al., 2024).

5.4.3. Noradrenalina ($\varepsilon = 0,135$) e a aprendizagem aversiva/defensiva

A noradrenalina (norepinefrina, NE), liberada a partir do locus coeruleus, modula o estado de alerta, a exploração e a plasticidade induzida pela surpresa (Aston-Jones & Cohen, 2005). Funciona como um “interruptor de ganho adaptativo” que ajusta a sensibilidade do sistema diante da incerteza: níveis baixos mantêm a exploração de estratégias conhecidas, enquanto níveis altos disparam a exploração de alternativas.

Nossos experimentos com SNN validam a existência de um limiar crítico em $\varepsilon \approx 0,40$: abaixo desse valor, a noradrenalina facilita a aprendizagem por meio do aumento da sinalização dopaminérgica e da potenciação da memória de trabalho; acima dele, gera saturação dos receptores $\alpha 1$ -adrenérgicos, interrupção da memória de trabalho e “colapso cognitivo” por caos sináptico. Isso explica a “Lei de Yerkes-Dodson” em termos neuronais: o desempenho ideal requer um nível moderado de excitação, nem tão baixo a ponto de gerar apatia, nem tão alto a ponto de produzir ansiedade.

No contexto do “fracasso produtivo” (Kapur, 2016), a noradrenalina mede a fase inicial de ativação e consciência da lacuna: o aluno experimenta uma discrepância entre seu conhecimento atual e as demandas do problema, o que gera um pico de NE que facilita a consolidação posterior quando a instrução corretiva é fornecida. Sem essa fase de “desequilíbrio” moderado, a aprendizagem se torna superficial e pouco transferível.

5.4.4. Homeostase neuroquímica e a “proporção áurea”

O modelo restrito ($\gamma + \delta + \varepsilon = 1$) simula a economia metabólica cerebral: o sistema tem recursos limitados de precursores aminoacídicos, energia ATP e espaço sináptico, pelo que o aumento de um neuromodulador implica necessariamente a redução de outros. Nossas experiências demonstram que a distribuição ideal não é simétrica (1/3, 1/3, 1/3), mas assimétrica: $\delta \approx 1/2$, $\gamma \approx 1/3$, $\varepsilon \approx 1/6$.

Essa “proporção áurea” tem implicações pedagógicas profundas: o sucesso técnico (associativo) constitui a base do bem-estar emocional, não sua consequência. Quando um aluno domina uma técnica ou compreende um conceito complexo por meio de instrução precisa (δ dominante), a redução da entropia cognitiva gera uma gratificação neuroquímica que estabiliza o sistema emocional (aumento indireto de γ). Por outro lado, quando se prioriza o “bem-estar” sem o suporte da competência técnica, o sistema carece da redução da incerteza que gera estabilidade duradoura.

5.5. Considerações sobre a metaplasticidade

Ao considerar diversos neurotransmissores, falamos sobre a plasticidade neuronal. Schmidgall et al. (2024) propõem a noção de metaplasticidade:

A capacidade das neurônios de modificar tanto sua função quanto sua estrutura em função da atividade é o que caracteriza a plasticidade sináptica. Essas modificações que ocorrem na sinapse devem ser organizadas com precisão para que as mudanças ocorram no momento adequado e na quantidade adequada. Essa regulação da plasticidade é conhecida como metaplasticidade, ou a “plasticidade da plasticidade sináptica”, e desempenha um

papel vital na proteção do cérebro em constante mudança contra sua própria saturação. Essencialmente, a metaplasticidade altera a capacidade das sinapses de gerar plasticidade ao induzir uma mudança no estado fisiológico dos neurônios ou sinapses. A metaplasticidade foi proposta como um mecanismo fundamental na estabilidade da memória, na aprendizagem e na regulação da excitabilidade neuronal. Embora sejam semelhantes, a metaplasticidade pode ser distinguida da neuromodulação, uma vez que os eventos metaplásticos e neuromoduladores muitas vezes se sobrepõem no tempo durante a modificação de uma sinapse.

A metaplasticidade constitui o mecanismo que permite ao sistema manter o equilíbrio dinâmico entre os três tipos de aprendizagem ao longo do tempo, ajustando a sensibilidade a novas experiências em função do histórico de aprendizagem anterior.

5.6. Conclusões: Rumo a uma pedagogia da eficiência cognitiva

A análise integrada dos três tipos de aprendizagem — afetiva/adesiva, associativa e aversiva/defensiva — por meio da ponte neurodidática estabelecida neste relatório permite formular as seguintes conclusões:

Primeira: A primazia da precisão técnica. Os dados experimentais com RNA demonstram que a eficiência máxima da aprendizagem requer a predominância da acetilcolina ($\delta \approx 53,4\%$). Isso não implica um reducionismo tecnicista, mas a compreensão de que a clareza instrucional é o fator que mais reduz o custo metabólico da aprendizagem. O professor eficaz atua como um “filtro de Maxwell” que organiza o caos informativo do ambiente em sinais precisos, permitindo que o sistema estudantil converja para o conhecimento com o mínimo esforço computacional.

Segundo: a segurança emocional como infraestrutura, não como objetivo. A serotonina ($\gamma \approx 33,1\%$) não é o fim da aprendizagem, mas sua condição de possibilidade. Sem o apoio da “visão de futuro” que ela proporciona, o sistema entra em colapso diante da primeira dificuldade. No entanto, o bem-estar emocional sustentado surge como subproduto do sucesso técnico, não como resultado direto de intervenções “emocionais” desvinculadas da aprendizagem de conteúdos.

Terceiro: o fracasso como ferramenta, não como fim. A noradrenalina ($\varepsilon \approx 13,5\%$) deve ser administrada com precisão cirúrgica. O “fracasso produtivo” só é eficaz quando projetado intencionalmente dentro da faixa eustress ($\varepsilon < 0,40$) e seguido por uma fase de “montagem” em que o professor fornece a instrução técnica que o aluno não conseguiu gerar por si mesmo.

O erro sem a consolidação posterior δ é mero ruído; o erro seguido de precisão é sinal.

Quarta: A integração homeostática como princípio orientador.

A educação eficaz não maximiza uma única variável, mas busca o equilíbrio dinâmico entre as três. A sala de aula como “aceleradora da plasticidade” deve fornecer simultaneamente: (a) precisão técnica que reduza a entropia cognitiva; (b) clima de segurança que permita a orientação para o futuro; e (c) desafios dosados que ativem a plasticidade sem gerar estresse crônico.

Quinta: A validade transversal do modelo. A correspondência entre os resultados do RNA tradicional, SNN, redes de Hopfield e mapas auto-organizados (SOM) valida que o modelo não é um artefato computacional específico, mas uma característica emergente de sistemas de aprendizagem adaptativa. A aplicação aos dados PISA-TALIS e ao contexto brasileiro demonstra sua relevância para políticas educativas de grande escala.

Em resumo, este capítulo estabeleceu que os tipos de aprendizagem não são categorias meramente descritivas, mas manifestações observáveis de estados neurocomputacionais otimizáveis. A missão da neurodidática contemporânea é traduzir essas descobertas em projetos instrucionais que maximizem a relação sinal-ruído, transformando a sala de aula em um espaço onde a eficiência cognitiva e a dignidade humana se reforçam mutuamente.

6. Replicabilidade da experimentação com redes neurais artificiais

Nas seções 2 a 5, realizamos um conjunto de experimentos, modelamos os resultados e extraímos as consequências para a aprendizagem. Agora, procederemos à replicação da experimentação. Os resultados são apresentados na tabela a seguir.

TABLA 6.1. RESULTADOS DE LOS EXPERIMENTOS CON RNA

γ	ϵ	δ	iterações (α)
0,25	0,25	0,25	471
0,25	0,25	0,50	402
0,25	0,25	0,75	454
0,25	0,50	0,25	682
0,25	0,50	0,50	537
0,25	0,50	0,75	566
0,25	0,75	0,25	772
0,25	0,75	0,50	983
0,25	0,75	0,75	948
0,50	0,25	0,25	469
0,50	0,25	0,50	460
0,50	0,25	0,75	482
0,50	0,50	0,25	587
0,50	0,50	0,50	715
0,50	0,50	0,75	699
0,50	0,75	0,25	787
0,50	0,75	0,50	839
0,50	0,75	0,75	714
0,75	0,25	0,25	528
0,75	0,25	0,50	406
0,75	0,25	0,75	357
0,75	0,50	0,25	488
0,75	0,50	0,50	677
0,75	0,50	0,75	547
0,75	0,75	0,25	944
0,75	0,75	0,50	735
0,75	0,75	0,75	895

Fuente: Elaboración propia con Simbrain 3.07

Com esta nova série de dados, verificamos as equações anteriores. Os resultados para a proporcionada pela Gemini são:

uintes.

Estatística	Valor	Descrição
R ² (Coeficiente de d determinação)	0,7241	O modelo explica 72,41% da variabilidade dos dados.
R ² Ajustado	0,6815	Ajustado pelo número de variáveis; mostra uma redução em relação ao conjunto anterior.
RMSE (Erro quadrático médio)	92,18	O erro típico das previsões nas mesmas unidades que a variável α ..
MAE (Erro absoluto médio)	74,56	O desvio médio absoluto entre o modelo e os dados reais.
F-statistic	17,04	Valor alto que confirma a significância global do modelo.
Valor p	< 0,0001	O modelo é altamente significativo (muito abaixo do limiar de 0,05).

E em relação à equação quadrática de Kimi:

Estatística	Valor	Descrição
R ² (Coeficiente de d determinação)	0,6781	O modelo explica 67,81% da variabilidade dos dados.
R ² Ajustado	0,5077	Ajustado pelo número de variáveis; mostra uma redução em relação ao conjunto anterior.
RMSE (Erro quadrático médio)	199,71	O erro típico das previsões nas mesmas unidades que a variável α ..
MAE (Erro absoluto médio)	167,68	O desvio médio absoluto entre o modelo e os dados reais.

F-statistic	16,94	Valor alto que confirma a significância global do modelo.
Valor p	< 0,0001	O modelo é altamente significativo (muito abaixo do limiar de 0,05).

Como se pode observar, o modelo Gemini oferece estatísticas ligeiramente melhores, embora ambos sejam satisfatórios. Em vez de escolher entre um ou outro, o que faremos agora será calcular novamente a equação com a série ampliada. Após todos os cálculos, a equação que tomaremos como definitiva é:

$$\alpha = 1568,50 - 982,86 \cdot \gamma - 1622,32 \cdot \varepsilon - 2443,90 \cdot \delta + 890,52 \cdot \gamma^2 + 239,42 \cdot \gamma \varepsilon - 362,21 \cdot \gamma \cdot \delta + 2515,13 \cdot \varepsilon^2 + 582,06 \cdot \varepsilon \delta + 1808,00 \cdot \delta^2$$

Que apresenta as seguintes estatísticas de robustez:

Estatística	Valor	Descrição
R ² (Coeficiente de determinação)	0,7739	O modelo explica 77,39% da variabilidade dos dados.
R ² Ajustado	0,7641	Ajustado pelo número de variáveis; mostra uma redução em relação ao conjunto anterior.
RMSE (Erro quadrático médio)	311,07	O erro típico das previsões nas mesmas unidades que a variável α .
MAE (Erro absoluto médio)	233,14	O desvio médio absoluto entre o modelo e os dados reais.
F-statistic	88,59	Altamente significativo
Valor p	1.11×10^{-16} (p < 0,0001)	O modelo é altamente significativo (muito abaixo do limiar de 0,05).


Que fornece valores para o ótimo de α

- $\gamma = \mathbf{0,331}$ (33,1%)
- $\varepsilon = \mathbf{0,135}$ (13,5%)

- $\delta = 0,534$ (53,4%)
- α mínimo previsto ≈ 367

Como pode ser observado nos gráficos a seguir.

GRÁFICO 6.1. VALORES PARA O ÓTIMO DE α



Chegamos assim à nossa proporção áurea.

$$\delta = \frac{1}{2}; \varepsilon = \frac{1}{6}; \gamma = \frac{1}{3};$$

Esta aproximação é muito interessante porque fornece um Erro Absoluto Médio (MAE) de 0,022 e um Erro Quadrático Médio (MSE) de 0,0007. Portanto, vamos considerá-la válida.

7. Consolidação da aprendizagem adesiva

7.1. Introdução

Determinamos a importância da aprendizagem adesiva ou afetiva. Agora, vamos aprofundar isso a partir de um modelo diferente de RNA. Enquanto o modelo ator-crítico usado anteriormente se concentrava no “o que fazer” (obter o queijo virtual), o modelo da rede de Hopfield se concentra em “como lembrar” (Hopfield 1982).

O glutamato é o neurotransmissor excitatório por excelência e o mediador fundamental da Potenciação de Longo Prazo (LTP), o mecanismo biológico que converte a atividade elétrica transitória em mudanças estruturais permanentes na sinapse. Através da ativação dos receptores NMDA e AMPA, o glutamato permite que os neurônios que “disparam juntos” se “conectem juntos”, criando os engramas de memória que nossa rede de Hopfield recupera a partir de estímulos parciais. A precisão na sinalização glutamatérgica é vital; enquanto seu fluxo controlado permite a consolidação da aprendizagem, sua desregulação pode levar à excitotoxicidade, saturando a rede e degradando a pegada da memória (Malenka e Bear, 2004).

Agora, o protagonista é o *glutamato*, que é o principal neurotransmissor excitatório, pois é responsável pela Potenciação de Longo Prazo (LTP) (Malenka & Bear 2004). Quando dois neurônios disparam juntos, o glutamato facilita que sua conexão seja mais forte no futuro. Isso é o “aprendizado hebbiano”: *neurônios que disparam juntos se conectam juntos* (já estabelecido em Hebb 1949).


7.2. Experimentação

Para verificar esse efeito na RNA, procedemos da seguinte maneira. Primeiro, definimos uma RNA, de acordo com o programa Simbrain, do tipo Rede de Hopfield. Utilizamos uma rede de 100 neurônios, dispostos visualmente em uma matriz 10x10. Em seguida, ativamos os 10 neurônios da diagonal e procedemos ao treinamento (*train*) da rede. Em seguida, desativamos todas as neurônios e voltamos a ativá-los duas primeiras da diagonal. Posteriormente (comando *step*), procedemos à simulação e imediatamente o restante das

neurônios da diagonal foram *ativadas*. Ou seja, quando uma neurônio libera glutamato, aumenta a probabilidade de que a neurônio seguinte também seja ativada. Em nossa rede de Hopfield, isso significa que, quando uma parte da diagonal é *ativada*, o glutamato “empurra” as neurônios vizinhas conectadas a também serem ativadas.

O conceito-chave é o LTP (Potenciação de Longo Prazo). Biologicamente, isso ocorre principalmente no hipocampo: quando dois neurônios são ativados repetidamente ao mesmo tempo, a eficiência de sua comunicação aumenta. No Simbrain, ao clicar *em “train”*, você está simulando que os receptores de glutamato (que atuam como canais de cátions, os receptores de N-metil-D-aspartato – chamados receptores NMDA –; os de ácido alfa-amino-3-hidroxi-5-metil-4-isoxazolpropiónico – receptores AMPA –) aumentam na sinapse, fazendo com que a conexão passe de 0 para 1. Podemos ver isso representado no gráfico 6 a seguir, que representa uma matriz de conexões de nossas 100 neurônios na simulação.

GRÁFICO 7.1. MATRIZ DE RELAÇÕES NEURONAIIS COMO RESULTADO DA REDE DE HOPFIELD



Fonte: Elaboração própria com Simbrain.

As células vermelhas (valor 1,0) representam o glutamato. São as sinapses reforçadas, a *marca* da diagonal treinada, que se mantém quando apenas 20% dos neurônios da diagonal são *ativados*. As células vermelhas (valor -1,0) representam a inibição. Elas são fundamentais para que a memória seja precisa e não se “espalhe” por todo o tabuleiro. A linha branca da diagonal, onde aparece *null*, indica que os neurônios não se conectam entre si, o que permite que o sistema seja estável (cf. Amit 1989 e Dayan & Abbott 2001).

Em nossos resultados anteriores, estabelecemos o ótimo de $\delta=0,50$. Esse valor é o que permite que os receptores NMDA de glutamato sejam ativados (a noradrenalina otimiza, facilita e regula a eficácia da sinalização glutamatérgica).

A consolidação da aprendizagem descrita nesta seção encontra seu correlato biológico na Potenciação de Longo Prazo (LTP), mediada fundamentalmente pelo sistema glutamatérgico. A passagem de uma informação volátil para uma marca mnemônica “adesiva” depende da ativação dos receptores NMDA, que atuam como detectores de coincidência molecular. Para que a aprendizagem seja eficaz, o sinal elétrico deve ser suficientemente intenso para expelir o íon de magnésio que bloqueia esses receptores, permitindo o fluxo de cálcio e a consequente reestruturação do citoesqueleto e do neuronal. Esse processo científico justifica didaticamente a necessidade de um “esforço cognitivo significativo”: sem uma ativação que ultrapasse certos limites de relevância e atenção, a rede neuronal não ativa seus mecanismos de plasticidade estrutural, resultando em uma aprendizagem superficial que se desvanece diante da falta de reforço sináptico.

A rede de Hopfield demonstrou que, com esses pesos consolidados, é capaz de recuperar a diagonal completa mesmo que receba apenas um estímulo parcial de 20%. Na neurociência, o glutamato é precisamente a molécula que permite que um sinal elétrico momentâneo deixe uma marca física duradoura. Se o nível de glutamato fosse muito baixo, a aprendizagem seria volátil; se fosse muito alto (excitotoxicidade), a rede ficaria saturada e todos os neurônios seriam ativados ao mesmo tempo (o que ocorre em um ataque de epilepsia).

Enquanto o modelo de Hopfield se concentra no glutamato para a potenciação de longo prazo (LTP), de acordo com Schmidgall et al. (2024), os astrócitos seriam os facilitadores biológicos que permitem que essa “marca física” seja estável e eficiente.

8. Categorização por meio de Mapas Auto-organizados (SOM) e o sistema GABAérgico

8.1. Introdução


Uma vez consolidada a memória por meio da plasticidade sináptica e da estabilidade da rede de Hopfield (simulando a ação do glutamato), surge um novo desafio biológico: a discriminação de estímulos. Para que o *rato virtual* não apenas se lembre, mas categorize efetivamente as informações sem que as memórias se sobreponham, entra em jogo o sistema GABAérgico. Nesta terceira fase, implementamos uma Rede de Mapas Auto-organizados (os chamados SOM, Self-Organizing Map ou mapas de Kohonen, em homenagem ao seu criador; ver Kohonen 1982), onde o GABA (*ácido gama-aminobutírico*, um neurotransmissor crucial no sistema nervoso central) atua como o mecanismo de inibição lateral necessário para moldar a aprendizagem. A inibição lateral mediada por interneurônios GABAérgicos é essencial para o contraste sensorial; sem ela, a aprendizagem seria uma amalgama difusa de dados sem fronteiras categóricas claras. Através de um processo de “o vencedor leva tudo” (*winner-takes-all*), o neurotransmissor inibitório permite que apenas os neurônios mais aptos para representar um estímulo específico permaneçam ativos, transformando o acúmulo de dados em um mapa topológico ordenado e funcional. Ou seja, esse mecanismo atua como um foco que ilumina uma única ideia, enquanto obscurece as distrações, permitindo que o “mapa do conhecimento” não se misture.

Isso pode ser *simulado* por meio de programação em python na plataforma *Google Colab*. Os resultados são os seguintes. Após a simulação do Mapa Auto-organizado (SOM), os resultados obtidos não apenas validam o modelo, mas oferecem uma representação visual de como a inibição lateral refina o aprendizado. A seguir, os resultados são analisados integrando as métricas e as representações gráficas geradas.

8.2. A estrutura do conhecimento inicial

Antes que a rede comece a aprender, os dados neuroquímicos apresentam uma estrutura intrínseca que o sistema deve ser capaz de identificar.

GRÁFICO 8.1. DISTRIBUIÇÃO DOS DADOS ORIGINAIS NA EXPERIMENTAÇÃO DA SOM




Este gráfico (uma projeção PCA, *Análise de Componentes Principais*) mostra como os estímulos de entrada são agrupados em um espaço bidimensional. É fundamental para entender o ponto de partida: existem nuvens de pontos diferenciadas para cada perfil neuroquímico. As 100 neurônios foram programadas de acordo com quatro grupos de 25 neurônios: um com alta serotonina, outro com alta acetilcolina, outro com alta noradrenalina e outro com valores aleatórios. A tarefa da rede é “entender” essa dispersão e dar-lhe um sentido topográfico.

8.3. Especialização e eficiência: o filtro da inibição

A primeira descoberta relevante na simulação é o Grau de Especialização Neuronal de 62%. Das 100 neurônios disponíveis na arquitetura do mapa, apenas 62 mostraram uma ativação significativa diante dos estímulos neuroquímicos apresentados. Este resultado pode ser visto no gráfico 8.

GRÁFICO 8.2. ESPECIALIZAÇÃO NEURONAL POR GRUPO na experimentação da SOM




Fonte: Elaboração própria com a plataforma Google Colab.

Na imagem de barras, observa-se que quase 40% da rede permanece em silêncio (a soma do que falta em cada barra até a média de 25%). Esse “silêncio” não é uma falha, mas o sucesso do Efeito GABAérgico. Assim como no cérebro humano, o GABA atua como um mecanismo de seleção que impede a superexcitação, permitindo que apenas os neurônios mais aptos para cada padrão se especializem, otimizando assim os recursos energéticos do sistema.

8.4. O processo de “esculpir” e amadurecimento da aprendizagem

A simulação mostra uma transição crítica: a redução do raio de vizinhança, com um valor σ de 3,0 para 0,003, o que representa uma redução de 99,9%.


GRÁFICO 8.3. REDUÇÃO DO RAIO DE VIZINHANÇA NA EXPERIMENTAÇÃO DA SOM



Fonte: Elaboração própria com a plataforma Google Colab.

O mapa SOM conseguiu organizar os diferentes estados neuroquímicos em regiões distintas, evitando a sobreposição de conceitos.

GRÁFICO 8.5. MAPA DE DISTÂNCIA U-MATRIX NA EXPERIMENTAÇÃO DO SOM




Fonte: Elaboração própria com a plataforma Google Colab.

Esta imagem é a “geografia da aprendizagem”. Nela, observa-se uma separação média de 63,6 unidades entre grupos opostos, como “alta δ ” e “alta ϵ ”. As áreas claras do mapa atuam como fronteiras físicas que o sistema construiu. Isso demonstra que a rede aprendeu a *categorizar*: ela sabe que a resposta à serotonina deve ser diferente da resposta à noradrenalina, atribuindo-lhes “territórios” neuronais separados para evitar confusão cognitiva.

8.6. Fidelidade da representação

Finalmente, a precisão do sistema é confirmada com um *erro de quantização* de 0,1609.

GRÁFICO 8.6. MAPA DE PESOS (E SEROTONINA) NA EXPERIÊNCIA COM SOM



Fonte: Elaboração própria com a plataforma Google Colab.

Ao observar como a rede (a grade do SOM) se ajusta sobre a nuvem de pontos dos dados originais, percebe-se uma adaptação quase perfeita. Esse baixo valor de erro confirma que a “escultura” realizada pela inibição lateral não distorceu as informações, mas capturou fielmente a estrutura subjacente dos estímulos de entrada.

Os resultados apresentados nessas imagens apoiam a tese de que o aprendizado ideal não é apenas um processo de adição de conexões, mas de refinamento por inibição. A combinação de plasticidade sináptica e inibição GABAérgica (redução do raio) produz um sistema de categorização que equilibra perfeitamente a capacidade de e e generalizar

conceitos (raio inicial grande) com a capacidade de se especializar em detalhes críticos (raio final pequeno).

9. Análise com Spiking Neural Networks (SNN)

A validação de hiperparâmetros em arquiteturas de aprendizado por reforço exige uma análise comparativa que transcenda a mera execução algorítmica. Ao avaliar um modelo Ator-Crítico com uma configuração de 20 ensaios (trials), um fator de desconto $\gamma = 0,331$, uma taxa de exploração $\varepsilon = 0,135$ e uma taxa de aprendizado $\delta = 0,534$, surge uma convergência de critérios entre as Redes Neurais Artificiais (RNA) e as Redes Neurais de Impulsos (Spiking Neural Networks - SNN). Esta paridade não é apenas funcional, mas estrutural, permitindo validar que o ótimo alcançado em um ambiente de computação tradicional possui um correlato robusto em sistemas biologicamente inspirados.

9.1. Dinâmica de Plasticidade e Aprendizado Acelerado

No modelo proposto, a taxa de aprendizado ($\delta = 0,534$) situa-se em um intervalo significativamente elevado. Em uma RNA, isto implica uma atualização agressiva dos vetores de pesos no espaço de estados. Ao transpor este fenômeno para uma SNN, tal taxa manifesta-se por meio de mecanismos de Plasticidade Sináptica Dependente do Tempo (STDP) e traços de elegibilidade dopaminérgicos.

A simulação com impulsos valida o ótimo da RNA ao demonstrar que, mesmo com uma janela temporal limitada a 20 trials, a força sináptica (w) experimenta uma potenciação de longa duração (LTP) suficientemente intensa para estabilizar a política do Ator. A rapidez desta convergência sugere que o sistema superou o limiar de ruído inicial, transformando disparos estocásticos em uma resposta direcionada e eficiente.

9.2. Temporalidade e o Horizonte de Recompensa

O fator de desconto $\gamma = 0,331$ define um agente com uma preferência marcada pela imediação. Em termos de redes de impulsos, este valor mapeia-se diretamente sobre as constantes de decaimento da membrana neuronal e a persistência do sinal de erro de predição temporal (TD error).

Enquanto na RNA o parâmetro γ simplesmente escala o valor dos estados futuros, na SNN ele atua como um filtro de relevância temporal: apenas os impulsos que ocorrem em estreita proximidade com o sinal de recompensa conseguem modular eficazmente a eficácia sináptica. A obtenção de um valor ótimo sob estas condições valida que a arquitetura é capaz de resolver tarefas de dependência temporal curta, onde a precisão do disparo no milissegundo é mais crítica do que o planejamento a longo prazo.

9.3. Estocasticidade e Robustez do Sistema

A introdução de um fator de exploração $\epsilon = 0,135$ representa um desafio para a estabilidade de qualquer rede. Na RNA, este parâmetro introduz variância na seleção de ações para evitar ótimos locais. Na SNN, a exploração é intrínseca e manifesta-se como ruído sináptico ou disparos espontâneos.

A validação do ótimo reside na capacidade da SNN em filtrar este "ruído" de fundo. Se a rede de impulsos converge para os mesmos valores de sucesso que a RNA, confirma-se que o aprendizado não é fruto de uma flutuação estatística, mas de uma reconfiguração sólida da topologia da rede. O sistema Ator-Crítico na SNN utiliza o erro de predição para "limpar" as ações exploratórias malsucedidas, reforçando unicamente a trajetória de disparos que conduz ao êxito.

9.4. Conclusão sobre a Equivalência de Modelos

Em conclusão, a simulação mediante redes de impulsos atua como um teste de estresse para os parâmetros da RNA. A correspondência entre o valor de estado calculado (V aprox 1,401 para uma recompensa unitária) e a taxa de disparo observada na SNN indica que os parâmetros selecionados operam em uma zona de equilíbrio homeostático. Esta análise interdisciplinar permite afirmar que o modelo não é apenas matematicamente consistente no domínio das RNA, mas possui viabilidade funcional sob as restrições da computação neuromórfica, consolidando a validade do ótimo identificado durante os 20 ensaios de treinamento.

10. Conclusões

Após a análise exaustiva dos resultados obtidos nas simulações de aprendizagem por reforço e a validação mediante modelos preditivos de inteligência artificial, estabelecem-se as seguintes conclusões:

- **Identificação do Ótimo Matemático (Modelo Restrito):** A experimentação avançada baseada no modelo de equilíbrio homeostático ($\gamma + \delta + \epsilon = 1$) situa o ponto de máxima eficiência (mínimo número de iterações α) em uma configuração onde a **acetilcolina (δ)** é o fator predominante. Os cálculos fornecem um valor ótimo para $\delta = 0,534$ (53,4%), seguido pela serotonina ($\gamma = 0,331$) e pela noradrenalina ($\epsilon = 0,135$). Este achado ratifica que a maquinaria de precisão e o ajuste fino dos pesos sinápticos são o motor principal da redução do custo de aprendizagem.

+4

- **Predominância da Acetilcolina (δ) na Eficiência Técnica:** Diferente das abordagens pedagógicas gerais, os dados brutos demonstram que a aprendizagem associativa e a supressão de interferências (dissonâncias cognitivas) gerenciadas pela acetilcolina são as que permitem alcançar o sucesso com o menor esforço computacional (α mínimo previsto aprox. 367). Isso confirma seu papel como seletor de atenção que reduz o "ruído" sináptico.

+2

- **Limites e Riscos da Noradrenalina (ϵ):** O modelo experimental identifica a noradrenalina como uma variável crítica de "U invertida". Embora um nível basal seja necessário para a exploração, um incremento acima de 0,40 dispara o número de iterações, provocando instabilidade, exploração errática e, finalmente, o colapso do sistema por caos cognitivo.

+2

- **O Fator de Desconto (γ) como Âncora de Estabilidade:** Embora neste modelo matemático a serotonina não seja a variável com maior peso percentual, seu valor de 0,331 é essencial para evitar a "miopia condutual". Sem este nível de

estabilidade, o agente é incapaz de atribuir valor aos estados intermediários que levam à recompensa, invalidando qualquer progresso técnico da variável δ .

- **Consolidação mediante Potencialização de Longa Duração (LTP):** Os testes com a rede de Hopfield e SNN confirmam que a aprendizagem não termina na iteração, mas na fixação física da memória mediada pelo glutamato. A precisão da sinalização é vital para evitar a excitotoxicidade que degradaria o traço de memória.
- **Validação da "Proporção Áurea" Experimental:** A convergência dos modelos de regressão e as redes neurais de picos permite concluir que a eficiência máxima na aprendizagem de uma RNA é alcançada com uma distribuição de recursos aproximada de 1/2 para a instrução técnica (δ) e 1/2 repartido entre a estabilidade emocional (γ) e a ativação exploratória (ϵ).

11. Bibliografía

- ABRAHAM, W. C., & ROBINS, A. (2005). Memory retention – the synaptic stability vs. plasticity dilemma. *Trends in Neurosciences*, 28(2), 73-78.
<https://doi.org/10.1016/j.tins.2004.12.003>
- AMIT, D. J. (1989). *Modeling Brain Function: The World of Attractor Neural Networks*. Cambridge University Press.
- ARNOLD, R. & HOLZKAMP, K. (2009). «Sobre el “cortocircuito enseñanza-aprendizaje”. Entrevista sobre el “aprendizaje”». *Revista de Sociología de la Educación-RASE*. 2 (1): 86-94.
- ASHCRAFT, M. H., & KIRK, E. P. (2001). The relationships among working memory, math anxiety, and performance. *Journal of Experimental Psychology: General*, 130 (2), 224–237. <https://doi.org/10.1037/0096-3445.130.2.224>
- ASTON-JONES, G., & COHEN, J. D. (2005). «An integrative theory of locus coeruleus-norepinephrine function: adaptive gain and optimal performance». *Annual Review of Neuroscience*, 28, 403-450.
<https://doi.org/10.1146/annurev.neuro.28.061604.135709>
- ATKINSON, R. C., & SHIFFRIN, R. M. (1968). Human memory: A proposed system and its control processes. En K. W. Spence & J. T. Spence (Eds.), *The psychology of learning and motivation* (Vol. 2, pp. 89–195). Academic Press.
- AUSUBEL, D. P. (1968). *Educational psychology: A cognitive view*. Holt, Rinehart and Winston.
- BADDELEY, A. D. (1986). *Working memory*. Oxford University Press.
- BANDURA, A. (1977). *Social learning theory*. Prentice-Hall.
- BEAR, M. F., CONNORS, B. W. & PARADISO, M. A. (2020). *Neuroscience: Exploring the Brain*. Wolters Kluwer.
- BLOKLAND, Arjan (1995). «Acetylcholine: a neurotransmitter for learning and memory?», *Brain Research Reviews*, 21 (3), 285-300 <[doi.org/10.1016/0165-0173\(95\)00016-X](https://doi.org/10.1016/0165-0173(95)00016-X)>

- BJORK, E. L., & BJORK, R. A. (2011). Making things hard on yourself, but in a good way: Creating desirable difficulties to enhance learning. En M. A. Gernsbacher et al. (Eds.), *Psychology and the real world* (pp. 56–64). Worth Publishers.
- BLOCKLAND, A. (1995). «Acetylcholine: a neurotransmitter for learning and memory?». *Brain Research Reviews*, 21(3), 285–300. [https://doi.org/10.1016/0165-0173\(95\)00016-X](https://doi.org/10.1016/0165-0173(95)00016-X)
- BOALER, J. (2019). *Limitless mind: Learn, lead, and live without barriers*. HarperOne.
- BOWLBY, J. (1982). *Attachment and loss: Vol. 1. Attachment* (2^a ed.). Basic Books. (1^a ed. 1969)
- BREIMAN, L. (2001). Random Forests. *Machine Learning*, 45, 5-32. <doi.org/10.1023/A:1010933404324>
- BRUNER, J. S. (1961). The act of discovery. *Harvard Educational Review*, 31 (1), 21–32.
- BRUNER, J. S. (1966). *Toward a theory of instruction*. Harvard University Press.
- CALKINS, L. M. (2001). *The art of teaching writing* (nueva edición). Heinemann.
- CAMPBELL, D. T. & STANLEY, J. C. (1963). *Experimental and Quasi-Experimental Designs for Research*. Boston: Houghton Mifflin.
- CHRISTENSEN, L. B., JOHNSON, R. B. & TURNER, L. A. (2014). *Research Methods, Design, and Analysis*. Boston: Pearson.
- CLARK, R., SAHAKIAN, B. J. & ROBBINS, T. W. (2020). «Psychological mechanisms and functions of 5-HT and SSRIs in potential therapeutic change selection, learning, affect, and social cognition: Lessons from the serotonergic modulation of action», *Neuroscience and Biobehavioral Reviews*, 119, 139-167.
- COBB, C. W. & DOUGLAS, P. H. (1928): «A Theory of Production». *The American Economic Review*, 18(1), 139-165
- COOK, T. D. & CAMPBELL, D. T. (1979). *Quasi-Experimentation: Design & Analysis Issues for Field Settings*. Boston: Houghton Mifflin.
- COOLS, R; NAKAMURA, K; DAW, N. D (2011). Serotonin and dopamine: unifying affective, activational, and decision functions. *Neuropsychopharmacology*, 36(1): 98-113. <[doi: 10.1038/npp.2010.121](https://doi.org/10.1038/npp.2010.121)>

- DAYAN, P., & ABBOTT, L. F. (2001). *Theoretical Neuroscience: Computational and Mathematical Modeling of Neural Systems*. Cambridge (Massachusetts): MIT Press.
- DECI, E. L., & RYAN, R. M. (1985). *Intrinsic motivation and self-determination in human behavior*. Plenum Press.
- DECI, E. L., & RYAN, R. M. (2017). *Self-determination theory: Basic psychological needs in motivation, development, and wellness*. Guilford Press.
- DEHAENE, S. (2019). *How we learn: Why brains learn better than any machine... for now*. Penguin Books.
- DOYA, K (2002). «Metalearning and neuromodulation.» *Neural Networks* 15, 495-506
[https://doi.org/10.1016/S0893-6080\(02\)00044-8](https://doi.org/10.1016/S0893-6080(02)00044-8)
- DOYA, K. (2007). «Reinforcement learning: Computational theory and biological mechanisms». *HFSP Journal*, mayo 1(1), 30-40.
<https://doi.org/10.2976/1.2732246/10.2976/1>.
- ENGELMANN, S., & Colvin, G. (2006). *Direct instruction: MSL (effective teaching)*. NIFDI Press.
- FREIRE, P. (1968). *Pedagogia do oprimido*. Rio de Janeiro: Paz e Terra.
- FRISTON, K. (2010). The free-energy principle: a rough guide to the brain? *Nature Reviews Neuroscience*, 11(2), 127-138. <https://doi.org/10.1038/nrn2787>
- GONZÁLEZ-REDONDO, Á., GARRIDO, J. A., HELLGREN KOTALESKI, J., et al. (2025). «Cholinergic modulation enables scalable action selection learning in a computational model of the striatum». *Scientific Reports*, 15, 34902.
<https://doi.org/10.1038/s41598-025-18776-3>.
- HASSELMO, M. E. (1993). «Acetylcholine and Learning in a Cortical Associative Memory», *Neural Computation*, 5 (1), gener, 32-44 <doi: 10.1162/neco.1993.5.1.32>
- HASSELMO, M. E., & SARTER, M. (2011). «Modes and models of forebrain cholinergic neuromodulation of cognition». *Neuropsychopharmacology*, 36 (1), 52-73.
<https://doi.org/10.1038/npp.2010.104>

- HATTIE, J. (2009). *Visible learning: A synthesis of over 800 meta-analyses relating to achievement*. Routledge.
- HEBB, D. O. (1949). *The Organization of Behavior: A Neuropsychological Theory*. Nueva York: John Wiley Amp Sons, Inc.
- HOLZKAMP, K. (1995). *Lernen. Subjektwissenschaftliche Grundlegung*. Frankfurt d. M., etc.: Campus Verlag.
- HOPFIELD, J. J. (1982). «Neural networks and physical systems with emergent collective computational abilities». *Proceedings of the National Academy of Sciences*, 79(8), 2554-2558.
- KAPLAN, S. T., LACETERA, N., & KAPLAN, C. (2012). The law of diminishing returns in biological systems. *Journal of Theoretical Biology*, 302, 12-20. <https://doi.org/10.1016/j.jtbi.2012.02.011>
- KAPUR, M. (2008). Productive failure. *Cognition and Instruction*, 26 (3), 379-424. <https://doi.org/10.1080/07370000802212669>
- KAPUR, M. (2014). Productive failure in learning math. *Cognitive Science*, 38 (5), 1008-1022. <https://doi.org/10.1111/cogs.12107>
- KAPUR, M. (2016). Examining the relationship between type of productive failure and learning outcomes. *Instructional Science*, 44 (3), 425–438. <https://doi.org/10.1007/s11251-016-9367-6>
- KOHONEN, Teuvo (1982). Self-Organized Formation of Topologically Correct Feature Maps. *Biol. Cybern.* 43, 59-69.
- LUO, Q. et al. (2024). «Comparable roles for serotonin in rats and humans for computations underlying flexible decision-making». *Neuropsychopharmacol*, 49, 600-608, <https://doi.org/10.1038/s41386-023-01762-6>
- MALENKA, R. C., & BEAR, M. F. (2004). «LTP and LTD: an embarrassment of riches». *Neuron*, 44(1), 5-21.
- MARTON, F., & SÄLJÖ, R. (1976). On qualitative differences in learning: I—Outcome and process. **British Journal of Educational Psychology**, *46*(1), 4–11. <https://doi.org/10.1111/j.2044-8279.1976.tb02980.x>

- McGONIGAL, K. (2015). *The upside of stress: Why stress is good for you, and how to get good at it*. Avery.
- MICHELY, J. et al. (2020). «A mechanistic account of serotonin's impact on mood». *Nat Commun* 11, 2335 <https://doi.org/10.1038/s41467-020-16090-2>
- NEUROBIOLOGY (2003). «Acetylcholine: Cognitive and Brain Functions», *Neurobiology of Learning and Memory*, 80 (3), 177-352 (número monográfico sobre la acetilcolina).
- POSNER, G. J., STRIKE, K. A., HEWSON, P. W., & GERTZOG, W. A. (1982). Accommodation of a scientific conception: Toward a theory of conceptual change. *Science Education*, 66 (2), 211–227. <https://doi.org/10.1002/sce.3730660207>
- ROGERS, C. R. (1961). *On becoming a person: A therapist's view of psychotherapy*. Houghton Mifflin.
- ROHRER, D. (2012). Interleaving helps students distinguish among similar concepts. *Educational Psychology Review*, 24 (3), 355–367. <https://doi.org/10.1007/s10648-012-9201-3>
- ROSENBLATT, L. M. (1978). *The reader, the text, the poem: The transactional theory of the literary work*. Southern Illinois University Press.
- RYAN, R. M., & DECI, E. L. (2017). *Self-determination theory: Basic psychological needs in motivation, development, and wellness*. Guilford Press.
- SARA, S. J. (2009). «The locus coeruleus and noradrenergic modulation of cognition. *Nature Reviews Neuroscience*», 10 (3), 211-223.
- SCHMIDGALL, S.; ZIAEI, R.; ACHTERBERG, J.; KIRSCH, L. etc. (2024). «Brain-inspired learning in artificial neural networks: a review». *APL Mach. Learn.* 2, 021501 (2024) <https://doi.org/10.1063/5.0186054>
- SCHULTZ, W. (2016). «Dopamine reward prediction error coding». *Dialogues in Clinical Neuroscience*, 18(1), 23-32.
- SHADISH, W. R., COOK, T. D. & CAMPBELL, D. T. (2002). *Experimental and Quasi-Experimental Designs for Generalized Causal Inference*. Boston: Houghton Mifflin.
- SKINNER, B. F. (1953). *Science and human behavior*. Macmillan.

- STANLEY, A. T., et al. (2023). «Norepinephrine release in the cerebellum contributes to aversive learning». *Nature Communications*, 14, 4852. <https://doi.org/10.1038/s41467-023-40548-8>
- SUTTON, Richard S. & BARTO, Andrew G. (2015). *Reinforcement Learning: An Introduction*. Second edition, in progress. Cambridge (Massachusetts): MIT Press.
- SWELLER, J. (1988). Cognitive load during problem solving: Effects on learning. *Cognitive Science*, 12 (2), 257–285. [https://doi.org/10.1016/0364-0213\(88\)90023-7](https://doi.org/10.1016/0364-0213(88)90023-7)
- SWELLER, J. (2011). Cognitive load theory. En J. P. Mestre & B. H. Ross (Eds.), *The psychology of learning and motivation: Cognition in education* (Vol. 55, pp. 37–76). Academic Press.
- TANAKA et al. (2007). Serotonin differentially regulates short- and long-term prediction of rewards in the ventral and dorsal striatum. *PLoS Biology*, 5 (12) :e1333 <https://doi.org/10.1371/journal.pbio.0050333>
- TOSI & YOSHIMI (2016). «Simbrain 3. A Flexible, Visually-Oriented Neural Network Simulator» <https://www.sciencedirect.com/science/article/pii/S0893608016300879>
- YOSHIMI et al. 2023. Neural Networks in Cognitive Science. Version 2023.1.1
- YOUNG, S. N., & LEYTON, M. (2002). «The role of serotonin in human mood and social interaction: Insight from altered tryptophan levels. *Pharmacology Biochemistry and Behavior*», 71 (4), 857-865.

12. Lista de esquemas, gráficos e tabelas

Esquema 2.1. Diagrama das experiências com RNA

Gráfico 2.1. Saturação das tentativas com RNA

Gráfico 2.2. Interface do Simbrain 3.07

Gráfico 3.1. Análise de clusters

Gráfico 3.2. Interface do Orange 3.37 para Random Forest

Gráfico 3.3. Representação tridimensional dos resultados das experiências ampliadas com Random Forest

Gráfico 6.1. Valores para o ótimo de α

Gráfico 7.1. Matriz de relações neurais como resultado da Rede de Hopfield

Gráfico 8.1. Distribuição dos dados originais na experiência com SOM

Gráfico 8.2. Especialização neural por grupo na experiência com SOM

Gráfico 8.3. Redução do raio de vizinhança na experimentação da SOM

Gráfico 8.4. Mapa de ativações por grupo na experimentação da SOM

Gráfico 8.5. Mapa de distância U-Matrix na experiência com SOM

Gráfico 8.6. Mapa de pesos (e serotonina) na experimentação com SOM

Tabela 1.1. Distinção entre RNA e SNN

Tabela 2.1. Resultados das experiências com RNA

Tabela 3.1. Análise de clusters

Tabela 4.1. Relação entre variáveis dos experimentos, parâmetros das RNA, neurotransmissores e áreas cerebrais

Tabela 6.1. Resultados da réplica da experiência

Índice

1. Ajuste e refinamento dos modelos: O paradigma da eficiência cognitiva (conclusões dos Relatórios 2 e 3)	Error! No s'ha definit el marcador.
1.1. Conclusões dos Relatórios 2 e 3	Error! No s'ha definit el marcador.
1.2. Aplicações didáticas: Design baseado na Homeostase do Sucesso	Error! No s'ha definit el marcador.
1.2.1. O Eixo Técnico-Associativo ($\delta = 0,534$)	Error! No s'ha definit el marcador.
1.2.2. O Eixo Afetivo-Estabilizador ($\gamma = 0,331$)	Error! No s'ha definit el marcador.
1.2.3. O Eixo Exploratório-Aversivo ($\epsilon = 0,135$)	Error! No s'ha definit el marcador.
1.3. Contribuição original: A educação como processo de redução de entropia cognitiva	Error! No s'ha definit el marcador.
2. Aplicações Didáticas: A Arquitetura da Realização Cognitiva e a Gestão da Entropia	Error! No s'ha definit el marcador.
2.1. O Eixo da Precisão Instrucional: A primazia da Acetilcolina ($\delta = 0,534$)	Error! No s'ha definit el marcador.
2.2. O Eixo de Estabilidade e Perspectiva: O Suporte Serotoninérgico ($\gamma = 0,331$)	Error! No s'ha definit el marcador.
2.3. O Eixo de Ativação e Exploração Moderada: O Limiar de Alerta ($\epsilon = 0,135$)	Error! No s'ha definit el marcador.
2.4. Síntese: a sala de aula como aceleradora da plasticidade	Error! No s'ha definit el marcador.
3. Desenho experimental e tempo de aprendizagem (α): A eficiência da precisão técnica	Error! No s'ha definit el marcador.
3.1. Otimização da taxa de convergência através do fator δ .	Error! No s'ha definit el marcador.
3.2. O custo metabólico do erro e o “vagabundagem cognitiva”	Error! No s'ha definit el marcador.
3.3. O papel da serotonina (γ) na janela de consolidação	Error! No s'ha definit el marcador.
3.4. Limiar de alerta e saturação (ϵ)	Error! No s'ha definit el marcador.
4. Sinergia PISA-TALIS: Validação Transversal do Modelo de Eficiência Cognitiva	Error! No s'ha definit el marcador.

4.1. O Índice de Clareza Instrucional (δ no PISA/TALIS)....	Error! No s'ha definit el marcador.
4.2. O Fator de Resiliência e Apoio (γ no PISA).	Error! No s'ha definit el marcador.
4.3. Projeto Experimental Híbrido: Comparação da “Redução da Entropia”	Error! No s'ha definit el marcador.
4.4. Conclusão: A Educação como Engenharia de Sinal	Error! No s'ha definit el marcador.
5. Análise do Contexto Educativo no Brasil: Um Desafio de Precisão e Engenharia Cognitiva	Error! No s'ha definit el marcador.
5.1. O Déficit de δ (Precisão Técnica) no Sistema Brasileiro	Error! No s'ha definit el marcador.
5.2. A sobrecarga de ϵ (alerta/estresse) e a instabilidade de ϵ	Error! No s'ha definit el marcador.
5.3. Projeto experimental adaptado: o “efeito salto” nas escolas brasileiras.	Error! No s'ha definit el marcador.
5.4. Conclusão para o contexto brasileiro	Error! No s'ha definit el marcador.
5.5. Desenho Experimental: “Projeto Sinal Limpo” (Redução da Entropia Escolar)	Error! No s'ha definit el marcador.
6. Tempo de aula (school lessons) e tempo de tarefas escolares (homework) ..	Error! No s'ha definit el marcador.
7. Fontes de dados	Error! No s'ha definit el marcador.
Bibliografia.....	Error! No s'ha definit el marcador.
0. Resumo executivo	2
Resumo por capítulos	2
1. Conceito, classificação e objetivo educacional das Redes Neurais Artificiais e considerações sobre a neurogênese	5
1.1. Conceito de Rede Neural Artificial	5
1.2. Classificação das redes neurais artificiais	5
1.3. Aplicação das Redes Neurais Artificiais em estudos sobre educação	7
1.4. Considerações sobre a neurogênese	7
2. Primeiros resultados da experimentação com RNA	9
2.1. Introdução.....	9
2.2. A questão do número de tentativas (variável β).....	11
2.3. Resultado dos experimentos	13
3. Modelização: Cálculo da equação subjacente aos resultados da experimentação, definição de clusters e mineração de dados.....	19

3.1. Cálculo da equação subjacente aos resultados da experimentação	19
3.2. Modelo restrito, de maior valor neurológico	21
3.3. Análise de clusters	22
3.4. Expansão dos resultados com um programa de mineração de dados	24
4. Construindo a ponte neurodidática (I): neurotransmissores e áreas cerebrais.....	28
4.1. Variável independente γ	28
4.2. Variável independente δ	30
4.3. Variável independente ε	31
4.4. Células gliais (astrócitos e microglia)	33
5. Construindo a ponte neurodidática (II): A ação dos neurotransmissores em áreas cerebrais está relacionada com tipos de aprendizagem	35
5.1. Introdução: Rumo a uma taxonomia integradora da aprendizagem	35
5.2. Os três tipos de aprendizagem: definição e fundamentação teórica	36
5.2.1. Aprendizagem afetiva ou adesiva	36
5.2.2. Aprendizagem associativa	38
5.2.3. Aprendizagem aversiva ou defensiva	40
5.3. Aplicações didáticas por áreas curriculares e níveis educacionais	42
5.3.1. Matemática	43
5.3.2. Ciências Naturais	45
5.3.3. Línguas (língua materna e segundas línguas).....	46
5.4. Bases neurocientíficas: Da ponte neurodidática à homeostase da aprendizagem	48
5.4.1. Serotonina ($\gamma = 0,331$) e a aprendizagem afetiva/adesiva	48
5.4.2. Acetilcolina ($\delta = 0,534$) e a aprendizagem associativa	48
5.4.3. Noradrenalina ($\varepsilon = 0,135$) e a aprendizagem aversiva/defensiva	49
5.4.4. Homeostase neuroquímica e a “proporção áurea”.....	50
5.5. Considerações sobre a metaplasticidade	50
5.6. Conclusões: Rumo a uma pedagogia da eficiência cognitiva	51
6. Replicabilidade da experimentação com redes neurais artificiais	53
7. Consolidação da aprendizagem adesiva	58
7.1. Introdução.....	58
7.2. Experimentação	58
8. Categorização por meio de Mapas Auto-organizados (SOM) e o sistema GABAérgico	61
8.1. Introdução.....	61

8.2. A estrutura do conhecimento inicial	61
8.3. Especialização e eficiência: o filtro da inibição	63
8.4. O processo de “esculpir” e amadurecimento da aprendizagem.....	64
8.5. Categorização espacial e diferenciação neuroquímica	65
8.6. Fidelidade da representação.....	67
9. Análise com Spiking Neural Networks (SNN).....	69
9.1. Dinâmica de Plasticidade e Aprendizado Acelerado	69
9.2. Temporalidade e o Horizonte de Recompensa	69
9.3. Estocasticidade e Robustez do Sistema	70
9.4. Conclusão sobre a Equivalência de Modelos	70
10. Conclusões.....	71
11. Bibliografia	73
12. Lista de esquemas, gráficos e tabelas	79
Índice	80